基于 relore 的开源项目历史知识图谱自动构建与可追溯问答

以 Flask 为主要实验对象的课程技术报告

2026年10月30日 · 期末统稿 · 规划与公共契约1.4.1

说明：本文记录已实现方法、真实工程运行、正式抽取实验、下游A/B、全池核验和第二仓库迁移结果。统计相对独立模型银标，不冒充人工金标；人员姓名、学号与组内互评保留为“待本人补充”，不由AI代填。

摘要

开源项目的技术决定分散在讨论、合并记录、源码与发布说明中，普通关键词检索容易只找到其中一环。本文面向公开GitHub Python仓库，实现基于relore的有限历史自动采集、显式知识构建和有出处问答系统。系统从仓库URL出发，按统一profile选择讨论及代码快照，保存来源原文、内容哈希和证据区间；利用GitHub元数据、git与AST提取可核对事实，并通过DeepSeek抽取原子决策及其明示理由。图谱区分关闭声明与实际关闭事件、发布提及与提交可达，避免把文本共现扩大为历史事实。检索与图增强使用相同冻结来源和统一回答器，输出可追溯的原子断言。真实Flask作业已经完成采集、抽取、校验及索引发布，共形成369条来源、40个完整讨论单元、24个代码快照、133个业务实体和183条关系，其中包含61个Decision。代码侧只读增量分片另生成18个Developer、384个Function、20条Authored、4条Merged和384条Defines关系，508条证据均通过原文区间复核。相对独立模型银标，30个测试单元的抽取Precision为0.5682、Recall为0.9615、F1为0.7143，明示理由完整覆盖13/15。下游实验保存24道题的48个A/B答案，并由24次匿名评审覆盖全部claims；20道测试题上，A/B事实覆盖分别为0.600和0.740，配对平均差为0.157，但固定种子95%描述性bootstrap区间[-0.122, 0.457]跨零，因此不宣称显著收益。全池92个位置完成两遍核验，6个首次失败位置经一次格式恢复重试后全部成功；6道候选均未确认证据不足，正确弃答率因合格分母为0而记为N/A。同一入口在pallets/itsdangerous上生成347条来源、30个完整讨论、17个文件快照、82个实体、78条关系和180条证据，依赖问题返回50条路径、25条证据和5条可核出处claims，但因采集缺口保持partial。该统计衡量银标一致性，不能视为人工金标准确率。

关键词：软件历史；知识图谱；知识抽取；证据追溯；检索增强生成

1 引言

成熟开源项目的当前代码能够说明系统怎样运行，却往往不能独立回答为什么这样设计。一项改动可能首先出现在Issue中的故障报告，经由多轮PR讨论确定方案，最终对应一个合并提交，并在稍后版本发布。开发者面对新项目时，需要跨页面、跨文件和跨版本恢复这条链。依靠记忆或单次大模型总结，很容易遗漏反对意见、混淆提议与采用状态，或把其他依赖库的决定归到当前仓库。

本项目采用课程“GitHub项目考古学家”方向，研究显式结构能否帮助组织这些分散证据。我们将任务限定为一个公开GitHub Python仓库的有限历史，不执行目标源码，不承诺采集全历史，也不训

练或微调基础模型。运行资料用于回答问题；开发资料用于定位缺陷并修改程序；隔离后的测试资料用于检验冻结方法。增加资料只扩大可查询范围，不会自动更新模型权重。

relore提供项目讨论的采集、存储与历史检索基础[1]。本项目复用固定源码，新增统一来源与证据契约、自动范围选择、代码版本事实、原子Decision、显式图及公平对照接口。我们希望回答两个问题：第一，模型能否从完整讨论中抽取属于当前项目的决定和明示理由，并给出可复算证据；第二，在同来源、同模型和同上下文预算下，图路径扩展是否改善跨来源问答，以及它在什么情形下引入噪声。两者都需要真实实验，不能由页面可运行或图节点数量代替。

前期独立小样曾真实接通技术链路，但暴露了依赖库归属错误、理由漏抽和显式链接漏采。因此后续实现围绕具体失败收紧证据条件，而没有以旧小样成功宣称课程项目完成。旧主题被登记为开发资料，不再冒充正式盲测。这种区分使工程修复与实验评价各自回答明确的问题。

2 数据集与知识图谱构造

2.1 自动范围与多源资料

使用者完成账号、数据库和费用配置后，只输入仓库URL。程序检查公开可读和Python支持，拒绝不在范围内的输入。默认course_small_v1最多读取100条PR候选和100条Issue候选，按更新时间及编号稳定排序，优先已合并PR和显式关联Issue，再补近期Issue。讨论单元总上限为40，不要求人工选择案例或补编号。显式关联补采同样占配额，仓库外引用只留下缺口，不启动跨仓库联合图。

一个完整讨论单元包含正文、全部分页普通评论、PR评审主体和行内评论及回复。不存在的类别记已确认空，未读到的页记缺失；不能因为正文已经取得，就把线程标为完整。程序记录端点、分页游标、失败与重试，请求达到上限后保存可恢复状态。有限采样本身不等于partial，实际未读分页或抽取失败才构成不完整。

代码模块根据已选PR自动定位合并提交、第一父提交和Python变化文件，最多检查40个相关提交、24个文件乘SHA状态和3个发布记录。在24个状态内预留有限默认分支包入口及一层内部依赖，以便回答模块职责；这一规则不读取测试问题。无正式Release时有限回退到tag，并说明接口顺序不等于发布时间；浅历史无法证明的可达性保留unknown。

真实Flask运行只输入pallets/flask仓库URL，没有手填线程、SHA或路径。冻结来源池共有369条SourceDocument、40个complete讨论单元和24个代码快照。来源包括API元数据、git输出、源码、发布说明、提交说明以及讨论正文和评论。网络累计182次，包含失败、重试与git网络操作，不能只以成功线程数代表网络成本。该范围是一次有限自动池，不是Flask全历史。

公开来源	完整讨论	代码快照	实体 / 关系	Decision
369	40	24	133 / 183	61

第二仓库使用pallets/itsdangerous[10]，只输入公开仓库URL，沿用course_small_v1及同一流水线，没有手选线程、SHA、路径或补图。作业ebfd8c8dae5e4bcf998a79fef35de981形成347条来源、30个完

整讨论单元、17个文件快照、82个实体、78条关系和180条证据，validate、graph与retrieval均为ready。采集保留10次HTTP 404、147个未补采显式引用以及外部目标和发布可达性缺口，因此作业状态诚实记为partial，success不等于全历史完整。依赖查询返回50条路径、25条证据和5条claims，所有引用ID可解析，引文逐字匹配冻结源码并复算SHA-256；另一条search查询为empty，也原样保留。该结果证明一次受限迁移和可追溯回答，不外推为任意Python仓库均可用。

2.2 冻结、稳定身份与证据

每个数据集在写首条来源前，由规范仓库、profile版本和job身份生成dataset_id；内容哈希另外保存，不循环参与身份计算。来源仅统一换行为LF，其余文字保持原样；source_id包含origin_key和文本哈希。API对象保存一份固定UTF-8 JSON表示，明确其为规范化对象而非逐字HTTP正文，保留非敏感GET端点、参数及状态，不保存认证头。

Evidence以source_id、start、end和quote表示，偏移为Unicode码点的零起始、左闭右开区间，程序要求text[start:end]与quote逐字相等。中文、emoji与重复引文均可能导致位置错误，因此重复引文必须借助明确位置或邻近上下文消歧，浏览器不能用UTF-16自行重算。URL用于跳转，冻结原文、哈希和位置用于复算；网页后续变化不应改变本次证据。

manifest保存文件与来源哈希、采集范围、版本、完整性和缺口。当前生产包的应用执行版本在发布后依主运行记录核对并补为独立exports元数据，明确补记时间与适用阶段，原manifest及已发布图指纹保持不变，不能声称完整应用SHA在采集前已经记录。后续build直接保存各阶段实际应用SHA、工作树状态及代码文件哈希，避免把relore上游版本误当作本组程序版本。

2.3 显式模式与关系语义

图的业务实体限定为Project、Issue、PullRequest、Commit、File、Release和Decision。File代表特定提交下的文件快照，同路径不同SHA不合并；Release由仓库与原样tag确定，同提交不同tag也不合并。普通评论和API响应作为来源保存，不再为每条评论创建业务实体。Decision保存主体、动作、采用状态、结论、理由及各自证据，通过ABOUT和EVIDENCED_BY连接主体及来源。

关系条件由证据性质决定。PR文字中的Fixes或Closes生成ClaimsToClose，只有官方关闭事件能够核对当前仓库对象并关联该PR或其已确认合并SHA时，才接受Closes。GitHub文档区分历史关闭事件和当前状态[2]，因此仅有merged、closed或同号提及均不够。MergedAs表示PR合并提交，Touches表示提交触及文件，ChangesTo连接明确前后文件，Imports只连接同SHA且已取得的内部目标。MentionsPR表示发布说明提及，ReachableIn表示提交对tag可达，两者都不直接证明首次发布或修复成功。

导入Neo4j前检查稳定ID、端点、关系方向、证据、仓库和dataset归属，错误使整批拒收。图库使用dataset与id组合约束[3]，全部遍历带数据集过滤，防止同号Issue或跨库实体串连。相同冻结包重复导入后读回全部记录并比较指纹；同一dataset内容变化则拒收，要求新版本。当前Flask生产结果为133个业务实体、183条关系、333条证据，61个Decision已包含于133实体，不能重复相加。

P3的Developer与Function属于新的只读增量分片，不向旧1.4.1生产图原地补写，因此不能把18个Developer、384个Function和508条证据直接加到上述生产计数。Developer只取自PR API顶层user和merged_by，不读取Commit author；Authored和Merged均连接Developer与PullRequest，Defines连接同SHA的File与Function。系统没有Developer→Commit边，避免将提交作者误推为PR作者或合并者。PullRequest→Commit仍由P1的MergedAs事实表达。

2.4 项目演化时间线

仅有分散实体还不能直接回答“项目怎样演化”。系统从同一冻结包中固定选择3个Release、5个公开Issue/PR案例和由MergedAs实际连接的4个提交，不使用测试问题或参考答案反向挑选事件，生成25个带时间戳的状态事件、5条案例链，并逐条复核46份证据的原文区间，见[15]。下表抽取其中对课程功能与缺陷演化最有代表性的链路。

时间（UTC）	演化事件	图谱关系与含义	证据边界
2025-05-13至2026-02-19	Release 3.1.1→3.1.2→3.1.3	Project HasRelease三个版本检查点	当前图没有ReachableIn边，不能把后续提交说成已随某版本发布
2026-02-12 20:32 – 21:07	Issue #5916→PR #5917；关闭时间晚于合并1秒	PR声明修复provide_automatic_options；Decision说明OPTIONS此前只能关闭、不能显式启用	该PR不在4个代码提交预算内，不补画文件或函数；相邻关闭时间不等于官方Closes
2026-07-14至08-11	Issue #6093→PR #6096→Commit 05e9c6b→app.py、testing.py	潜在IPv6地址的.partition(":")修复；Decision明确选择main而非bug fix发布	Decision理由是不预期还有bug fix版本且问题不严重；该判断不等于版本已发布
2026-06-23至08-11	Issue #6065→PR #6133→Commit d8eaaba→sansio/scaffold.py、test_basic.py	为RFC 10008的HTTP QUERY增加app.query路由装饰器，属于功能演化案例	关联来自PR文字ClaimsToClose；没有官方关闭事件时不升级为因果修复证明
2026-10-07 13:48 – 13:56	PR #6168→Commit 728c5e4→cli.py、helpers.py	移除Python 3.10支持，体现版本与兼容策略变化	Decision理由为3.10将在功能版本后六个月内EOL；未采集后续发布

IPv6案例还能继续进入P1+P3合并分片的函数层：PR #6096经作者、合并者和提交连接到src/flask/testing.py，再经Defines指向flask.testing._get_werkzeug_version，两条方向路径均已在真实Neo4j验收。该函数层只存在于独立合并验收数据集，当前生产时间线止于File，不能把两种版本混写。时间线的价值是把“问题报告、方案声明、合并动作、代码变化和版本检查点”按时间组织，同时仍然保留每类事实的证据强度差异。

3 任务定义

知识抽取输入是一个完整讨论单元及可见主体目录，输出是原子Decision集合。模型需判定对象属于哪个仓库、讨论采取什么动作、状态是proposed、accepted还是rejected，并单独抽取原文明示理由。没有理由不要求模型补出“合理解释”；无法唯一映射主体的候选保留unresolved，依赖库决定保留external_project，不强挂本地实体。

下游输入是一条自然语言问题和已发布数据集。系统输出原子claims、证据、真实路径与缺口。claims中每项结论必须能回到最终上下文的原文片段，不允许额外生成未经校验的summary。search、trace、timeline、dependencies和compare共享接口，后两类在采样范围缺资料时可返回unsupported。状态分别表达成功、无支持材料、不支持和运行错误；断库或模型失败不能计为正确弃答。

我们把显式图的作用限定为组织和扩展证据。它使“讨论理由、PR、提交、文件”能够通过已有边串联，但不会制造缺失关系或让回答器知道未采事实。因此跨来源回答应同时给出相关片段及路径，不能只展示一张关系图就宣称完成多跳推理。尤其“提交发生过”“发布提及过”和“功能真正修复”属于不同强度的结论。

4 系统方法

4.1 唯一流水线与恢复

系统由Python3.11实现，阶段依次为discover、collect、code、extract、validate和index_graph。P1维护唯一持久作业及公共CLI，P3提供代码事实，P4提供采集器、抽取和回答，P2提供图与检索，P5只调用构建与查询接口。页面刷新复用活跃job，不产生另一套编排；进程退出后显式resume检查已完成阶段哈希，只重试尚未完成阶段。

作业保存请求、配置快照、阶段结果、覆盖、用量和失败。单worker采用操作系统文件锁，进程退出后系统释放占用，空锁文件也可恢复。只有真实LLM抽取、公共校验、图和共同检索均完成，才发布ready或partial。ready说明约定有限范围内各阶段完成，不表示知识全对或资料全量。预算不足、凭据缺失及可恢复外部限制为blocked；失败时保留已有原文和检查点，不能偷偷重爬或重复付费。

4.2 固定代码与静态演化事实

P4保留relore 0.3.19固定提交06a1c99c4653e9db899a18e96d8ff0ee6b419815的源码、许可证与来源记录。采集、线程存储和词法检索复用上游能力，项目适配层负责URL、选单、冻结回放与公共记录映射。报告把上游已有能力和本组新增代码分开记载，不将开源移植等同于重新发明检索器。

P3只静态读取目标git对象，不安装或执行历史源码。程序用diff识别增加、修改、删除、改名与复制，删除指向父版本实际文件。AST提取静态import和顶层定义，字节列偏移转换为公共码点偏移；外部依赖、未采目标、读取失败和解析失败单列缺口。静态import不等于运行调用图，24份快照也不支持任意API或全项目职责判断。

新增事实从PR API顶层user与merged_by提取Developer，并从24个文件乘SHA快照的顶层FunctionDef/AsyncFunctionDef提取Function。实测只读分片得到18个Developer、384个Function、20条Authored、4条Merged和384条Defines关系，全部508条证据均通过Unicode原文区间检查；ClassDef和方法不计入Function，两次重放稳定ID一致。固定链已核对为PR #6096（作者lkk7、合并者davidism）→提交05e9c6bd630ecf4ec0ec884b1fc7901663737bc7→src/flask/testing.py→flask.testing._get_werkzeug_version，函数位于第100至106行。PR→提交边沿用已有MergedAs，P3不生成Developer→Commit。公开验证见[12]。

4.3 结构化模型抽取与用量

生产使用DeepSeek API，实际请求明确设置deepseek-flash、thinking disabled、temperature 0、max_tokens 4096、最大2次重试、200000输入字节上限和90秒超时。讨论按最多20000码点分块，邻块保留400码点重叠；每块保存覆盖及run_id。模型返回Schema约束候选和逐字引文，程序完成主体映射、证据定位和稳定身份赋值，不要求模型猜URL或编实体ID。

共享网关保存输入、实际配置、提示版本、Schema、原始响应、结束原因和每次尝试。API成功但length截断、空输出、JSON或引文校验失败均不算成功[4]。重试最多两次，失败仍占用预算并保留；同一run由输入、模型参数、提示和repeat_index共同确定，缓存重放不发新请求，改变方法不能冒用旧缓存效果。reference和judge从首次请求起进入P6私有目录，生产任务拒绝该路径。

真实生产抽取有40个run和42次尝试，包含重试，累计621615输入token与24717输出token。旧manifest中的model_requests=0来自代码阶段局部值，不代表全流程零模型调用。用量导出分别列阶段、新增、复用和累计attempt；历史record中的1.440966元为当时保守上界，按42个生产attempt身份在P4共享账本只读核对，核算为0.657140元，未知用量上界为0；不混入开发抽取或参考评审费用。最终共享账本保留同一历史序列，没有重置：approved=20元、effective cap=19.84元，387次attempt中362次settled、25次uncertain，保守累计9.465795元，由known usage 7.771385元和unknown upper 1.694410元组成，余10.374205元。本轮新增1.092283元，其中第二仓库0.589461元、全池失败位置格式恢复重试0.502822元。

4.4 同源检索与图增强

每个数据集在PostgreSQL建立独立冻结relore空间，从已保存ThreadPayload无网络回放，并核对来源映射。后续同仓库重新采集不会改变旧数据集检索结果。共同适配层让发布说明、提交说明、源码、git输出和API响应与讨论一样可被固定词法检索，按source_id稳定打破同分，并与真实relore排序作固定排名融合。

A组使用共同检索种子和统一回答器，B组在同样种子上扩展最多三跳图路径，再使用同一回答器。主体解析由编号、URL、目录及检索结果共同完成，不要求用户复制内部ID。两组均按同一渲染规则去重、排序和截断，最终上下文上限为12000个Unicode码点，标题及结构字段占预算。裁剪同步修改区间与quote，并保留最终实际送入模型的文本，而不是只保存截断前候选。

这种设计将方法差异限定为图扩展。A不能只读讨论而让B独占源码或发布文本，也不能给B额外来源。图扩展可能补齐跨源环节，也可能用相关但无用的片段挤占上下文，因此其收益必须由最终可见证据和回答共同评估，不能由路径更多直接推断。

5 实验设计与正式结果

5.1 独立参考与隔离

正式实验由P6在来源冻结后独立控制。讨论样本为40个完整单元，按主题划分10开发、30测试；代码为12个文件乘SHA样本，4开发、8测试；下游24题，4开发、20测试。生产池有24份快照，但不能把它们全部混称正式12个代码样本。跨线程同主题必须分到同组，已看过并用于修复的旧主题保持开发身份。正式结果按冻结协议、固定分母和公开汇总报告，不根据事后结果删除题目或改写参考。

参考生成覆盖完整原文，包含生产没有抽到的事实，不能只检查已有Decision。模型参考与独立复核都保存请求、输出和分歧，称为模型参考或银标，不宣称人工金标。下游问题在冻结来源后生成，测试生产输入仅含问题身份及正文，不带答案、题型、来源提示或可回答标签。测试参考、盲化映射和评分不会进入图、检索或开发调参材料。

证据不足题必须对整个冻结可检索池核验，单个主题没有答案不够。定位修复、决策理由和版本代码关联中保留跨源覆盖，并至少包含一题有源码依据的有限模块职责或依赖实答。第二仓库只用于换URL免改代码检查，不追加另一套正式参考，也不以单次迁移声称任意仓库通用。

5.2 指标与公平对照

抽取按参考与预测一对一匹配得到TP、FP、FN，报告Precision、Recall和F1。重复预测计FP，完整漏抽计FN，有应抽事实而全漏时F1为0；分母为零记N/A。理由指标以参考中明确stated且有效的决定为分母，漏整条、空理由和部分理由均不能从分母消失。除总分外，分别报告归属、状态、理由和引用错误。

代码实验只报告冻结快照范围内的正确、错误、unknown及解析失败，不在缺少完整事件参考时报告事件召回。下游报告原子事实覆盖、证据组召回、无依据断言率、正确弃答率、延迟及token费用。必要的不同环节分为不同证据组，组内替代片段只计一次；召回按最终prompt中完整可见区间计算，候选命中、节点名和最终引用都不能替代这一口径。

评审覆盖全部返回claims，包括没有引文的断言。unsupported断言除以全部断言构成无依据断言率，unclear另列。模型或服务失败不视为正确弃答，可回答题中的失败或空输出记零覆盖；若评审重试后仍漏项，总体指标记N/A并单列已评子集和覆盖。两组使用同一问题、原文池、模型、提示、参数、上下文预算和盲化评审，报告胜例、败例与无差异，不预设图谱胜出。

5.3 工程与正式抽取结果

当前真实URL作业已完成全部六阶段并发布ready，actual_llm_extraction、graph_ready和retrieval_ready均为true。公共来源、证据及端点检查通过；图记录从冻结文件构建并读回校验。主代理独立复跑过受影响的公共流水线、模型、图查询和界面检查。这些证据证明模块可协同运行，不能写成抽取准确率，也不能用某个开发问题的成功回答代替A/B总体结论。

P6已发布全部61个生产预测的逐项评审及40单元的正式抽取汇总[7]，评审覆盖为1.0，无漏评预测或未决参考。测试集30个完整单元得到TP25、FP19、FN1，Precision为25/44=0.5682，Recall为

25/26=0.9615，F1为0.7143。开发集10单元为TP10、FP7、FN2，F1为0.6897。两组分开报告，不将调试数据与正式测试合并成总体成绩。

划分	TP / FP / FN	Precision	Recall	F1	理由完整覆盖
开发10单元	10 / 7 / 2	0.5882	0.8333	0.6897	9 / 11
测试30单元	25 / 19 / 1	0.5682	0.9615	0.7143	13 / 15

测试集中有15个参考决定明确包含理由，13个成功抽中并完整保留理由，覆盖为0.8667。两项缺口分别为整条决定漏抽1和理由为空1；状态错误1与理由为空发生在同一项，不能相加成三个独立缺口。开发理由覆盖为9/11=0.8182，另两项为整条漏抽。结果表明，在本冻结银标下，系统召回较高而精度明显较低，仍有大量未匹配预测，不能只展示成功链或用高Recall掩盖这一问题。

独立模型银标本身并不完美。开发负例已保留一项已知银标遗漏，生产中有原文支持而银标缺失的预测仍按未匹配计算，没有在看过生产输出后回填参考。因此FP含义是相对冻结银标未匹配，不能全部解释为经人工确认的事实错误；这种限制与指标同时报告。12个源码快照的解析、顶层符号、模块说明及已发出Imports的引文和同SHA核验通过，但不构成未采依赖完整性或事件召回。

5.4 问答A/B与全池核验

24道题分别运行A、B两组，共形成48个答案，其中32个正常返回、15个为空结果、1个生产失败；24次匿名评审全部完成，覆盖48个答案中的全部claims和参考事实，公开汇总见[8]。20道测试题的结果如下表。A组事实覆盖30/50=0.600，B组为37/50=0.740；A组证据组召回35/55=0.636，B组38/55=0.691；A组无依据断言1/39=0.026，B组2/47=0.043。B组事实覆盖更高，但返回的claims更多、无依据断言率也更高，说明图扩展同时带来补充证据和额外噪声。

组别	事实覆盖	证据组召回	无依据断言率	中位延迟
A：共同检索	30/50 = 0.600	35/55 = 0.636	1/39 = 0.026	2285 ms
B：A加图扩展	37/50 = 0.740	38/55 = 0.691	2/47 = 0.043	2688 ms

15道具有配对事实覆盖的测试题中，B胜5题、A胜4题、6题持平；B减A的平均覆盖差为0.157。以固定种子20261030对题目做描述性配对bootstrap，95%区间为[-0.122, 0.457]，跨零且样本仅来自一个冻结项目，因此只能报告观察到的方向性差异，不能宣称显著收益或一般化因果效果。B组中位延迟比A组高约403毫秒，也提示图扩展需要计算与上下文预算代价。

全池不足证据核验首轮92个位置中86个成功、6个因结构或引文校验失败。系统只对失败位置沿原分片和缓存做一次格式恢复重试，6个全部成功；旧失败记录与备份保留，最终92/92位置完成两遍核验。6道候选均出现非空证据，确认证据不足数为0，因此正确弃答率的分子为0、合格分母也为0，按约定记为N/A。该N/A的原因是核验完整但没有证据不足题，不是核验未完成；15个空结果和1个生产失败也不能自动记作正确弃答。若把检索未命中或服务失败算作弃答，会系统性高估系统能力。最终验收矩阵见[13]。

5.5 第二仓库迁移检查

pallets/itsdangerous使用同一python -m historykg.cli build <repo_url>入口和默认course_small_v1，没有手工选择讨论、SHA或文件，也没有修改源码、图关系或证据。最终作业形成347条来源、30个完整讨论单元、17个文件快照、82个实体、78条关系和180条证据；公共validate返回ok，graph_ready与retrieval_ready均为true。由于采集仍有10次HTTP 404、147个未补采显式引用、74个未采内部Import目标、60个发布可达性unknown和78个外部或未解析对象，作业整体状态保持partial。partial描述记录缺口，不否定已生成并校验的图和检索结果。公开验收见[11]。

真实依赖问题询问src/itsdangerous/timed.py导入或依赖哪些模块，返回50条路径、25条证据和5条claims，分别覆盖同包encoding、exc、serializer、signer以及标准库依赖。5条claim引用的evidence ID均可解析，所有引文均为冻结源码的逐字子串，来源SHA-256重新计算一致。另一条search查询返回empty，也作为查询状态保留。该答案只证明一只小型公开Python仓库可在不改代码的情况下完成有限迁移和可追溯依赖回答，不能扩展为全历史完整或任意体量仓库的通用保证。

Windows验证使用GitHub托管windows-2022环境安装锁定Python依赖，并启动原生PostgreSQL16.4及Neo4j5.26.0，重建合成fixture和公开Flask冻结包。公开平台验证摘要deliveries/P1/2026-10-30/platform_validation.json所对应run的150项JUnit测试无失败、无跳过，Flask冻结包首次加载与幂等重复加载均ready，数据集指纹保持 5cbe7b6f68a74d31ebf1fceeb7a00fd16d9b3737066b1ac7e9e51f90be955cfe，新增模型请求为0。该平台快照当时的macOS主线150项测试全部通过；期末最终真实服务回归为181项通过。该流程不配置模型密钥，不是Windows在线抽取或同学本机实测，缓存与重放均显式标记。

6 原型系统与使用展示

6.1 使用流程与证据展示

原型采用Streamlit单页面，按“提交仓库、观察构建、围绕已采历史提问”组织。安装者一次配置数据库、GitHub只读访问、DeepSeek密钥与共享预算后，使用者只需输入公开仓库链接。页面调用start_build、get_build和resume_build，显示后端真实阶段、完整单元、来源数和快照数。作业与dataset内部身份放入诊断区，避免让普通用户选择技术路径。

queued、running、blocked、failed和unsupported均不开放问答，只有ready或partial允许输入问题；partial持续展示缺口。页面重绘不重建任务，同一次响应保存在会话中，避免刷新重复调用模型。暂停或失败通过显式恢复入口接续检查点，不要求使用者重新选材料。界面不以“已抓到若干来源”代替“可查询图已发布”。

答案按顺序呈现全部claims.text，每项链接到相应证据，包含原文、来源URL、作者时间、版本与位置。关系链来自公共查询结果，不由页面临时推断或美化；没有Decision时仍可呈现已有PR、提交及文件链。empty、unsupported和error分别解释资料不足、范围限制和调用故障。课堂备份模式读取带原运行时间的真实缓存，清楚标为重放并关闭在线输入，不能将重放计作在线时延。

6.2 真实案例与边界

真实页面已用同一Flask作业展示源码职责问题：在冻结的src/flask/testing.py中询问FlaskClient.session_transaction为何使用临时请求上下文及怎样处理会话与Cookie，系统返回6条claims，证据32至37逐条对应源码。每条claim可查看逐字引文、Unicode位置、来源编号、原始链接和数据版本；同一冻结重放包还保留一份empty响应，没有把资料不足改写为成功。界面与截图记录见[9]。

可用开发例是Flask PR6133：本地测试调整的明示理由是适应尚未发布的Werkzeug。修复后的抽取保留本地决定及理由，同时将Werkzeug新增client.query识别为外库候选，不挂到Flask主体；回答器输出带逐字引文的claims。该例属于已登记开发回归，说明具体问题怎样被发现和修正，不进入正式测试成绩，也不替代仅URL的产品验收。

页面可运行和单题可追溯只证明交互闭环，不能替代第5节的总体统计。截图、冻结响应和验证记录只对应同一作业与同一数据版本；换仓库后必须重新采集、抽取和建图，不能复用Flask的实体或答案。

6.3 期末展示材料

期末汇报统一采用demo/final/期末汇报_20261030最终版.pptx，共10页，覆盖研究问题、自动流程、Schema与证据契约、Developer/Function增量、真实数据范围、固定跨源链、原型问答、抽取与A/B结果、复现费用和六角色贡献。该目录另附逐页讲稿、演示步骤及10张由Microsoft PowerPoint原生导出的预览图。最终PPTX原件已纳入版本控制；最终打包工具会校验PPTX存在、格式正确且由待打包提交跟踪，不能只以预览图替代。期中五页版本只作为历史阶段材料保留，不再代表期末状态。材料说明见[14]。

7 复现、费用与局限

复现分三个层次。第一层使用已保存评分和统计代码重算数字，不再请求模型；第二层使用冻结来源、图记录和relore输入重建数据库与页面，验证哈希、幂等性及检索；第三层重新调用外部模型，要求使用者自己的账号、密钥和额度，并承认别名、服务版本及随机性可能导致输出不同。交付锁定依赖、固定上游、源码、公开冻结包、模型记录及实验归档，私有参考由P6在正式结束后按课程范围发布。

本次公开最小重建包保存原manifest和18份带哈希JSONL，以及无网络检索回放输入和明确标为事后补记的执行元数据。它不包含密钥、个人配置、完整clone或私有测试。未来源码变更与已有生产运行分别记录，不能用当前HEAD假装过去的执行版本。原manifest中历史个人capture路径仅作原运行出处记录，重建读取包内相对路径，无需原电脑目录。

费用由唯一SQLite账本以整数微元控制，请求前预留上界，失败和重试不消失。P4根据实际时段与缓存命中元数据对账，原保守记录保留历史语义；最终账本未重置，approved=20元、effective cap=19.84元，保守累计9.465795元，其中known usage 7.771385元、unknown upper 1.694410元，剩余10.374205元。全池重试和第二仓库运行分别新增0.502822元、0.589461元，合计1.092283元。P1的冻结重建和统计重算不产生新增模型请求，服务商账户余额也不替代内部账本审计。

方法存在若干实际局限。首先，有限近期采样无法恢复全生命周期，未采发布或文件不能凭空回答。其次，静态AST只提供局部依赖事实，动态导入与运行行为不在当前范围。再次，模型可能把观点误判为决定、遗漏理由或在引文真实时仍作出错误归属，格式和偏移校验不能证明语义正确。第四，独立模型参考与judge仍可能共享偏差，银标结果需要结合覆盖及分歧解释。第五，全池虽已完成92/92位置的两遍核验，但6道候选均未确认证据不足，正确弃答率因合格分母为0而N/A；该N/A不能解释为核验失败。第六，A/B实验仅覆盖一个冻结项目的20道测试题，配对区间跨零，不能据此宣称图谱普遍优于普通检索。第七，pallets/itsdangerous迁移作业因10次HTTP 404和147个未补采显式引用等缺口保持partial，单题通过不能外推为全历史完整或任意仓库通用。第八，P2已在真实Neo4j与PostgreSQL服务上完成P1+P3合并分片的四跳验收，临时图命名空间和PostgreSQL schema均已清理；当前生产图仍是旧1.4.1版本，不包含Developer与Function，不能把本次重放验收冒充为生产图已扩容。图谱将这些信息显式组织，但不会自动消除错误。

8 结论与后续工作

项目已将公开仓库URL、完整讨论采集、有限代码事实、真实模型抽取、显式图和同源检索接入一个可恢复流程。统一证据契约使讨论、API、git与源码能够使用同一套原文位置复算，关系语义则限制了从文本声明到历史事实的无依据升级。真实Flask生产作业证明这条有限流程可以执行并发布，冻结包支持无新增模型请求的重建。

正式抽取测试显示银标F1为0.7143、理由覆盖为13/15，同时精度0.5682暴露出预测与参考的明显分歧。下游20道测试题中，图扩展组事实覆盖由0.600升至0.740，但配对差0.157的95%描述性区间跨零，且B组无依据断言率和延迟更高，因此结论是“观察到方向性收益，但证据不足以宣称显著或普遍有效”。全池92/92位置完成两遍核验，6道候选均确认证据充分，正确弃答率因无合格题而N/A；pallets/itsdangerous以partial状态完成受限迁移，依赖答案的50条路径、25条证据和5条claims均可追溯。冻结记录另生成25个事件、5条案例和46份逐字复核证据组成的项目演化时间线，覆盖缺陷、功能、版本与兼容策略变化，同时保留发布映射和Issue关闭因果边界。后续工作应优先处理真实采集缺口、生产图扩展、Windows字体替换检查、人工核验和课堂彩排，而不是根据分数修改冻结来源或删除难例。期末材料包含PDF、10页期末PPT、代码数据及复现材料；真实成员姓名、学号、互评与课堂表达由成员本人完成。

9 人员与工作安排及组内互评

以下只列可由仓库、冻结数据、运行记录或交接核对的角色贡献。P4前期独立调研、总体方案、架构迭代、规划协作框架、期初原型与试跑保留原贡献归属，不因后续模块接收而转记给集成者。姓名、学号和互评不根据Git提交作者、聊天昵称或文件名推断。

角色	主要职责	可核验贡献	证据
P1 数据与集成	公共数据契约、URL发现、唯一作业编排、冻结、总集成与报告统稿	实现来源与证据契约、稳定身份、可恢复流水线；完成Flask URL作业369来源、40完整讨论和24快照；组织该阶段150项跨平台验证并参与最终181项真实服务回归	historykg/pipeline.py；deliveries/P1/2026-10-30/handoff.md；platform_validation.json
P2 图谱与查询	图模式导入、Neo4j、同源检索隔离与公共查询	发布133实体、183关系、333证据；实现数据集过滤、查询服务、A/B共同检索与图扩展接口	historykg/graph/store.py；historykg/query/；deliveries/P2/2026-10-30/handoff.md
P3 代码与演化	提交、发布、文件和静态代码事实	自动定位24个文件乘SHA快照；只读增量生成18 Developer、384 Function、20 Authored、4 Merged、384 Defines及508条证据；核对PR #6096到函数定义的固定链	historykg/code/；deliveries/P3/2026-10-30/developer_function_validation.json；deliveries/P3/2026-10-30/developer_function_handoff.md
P4 开源移植与模型抽取	relore移植、采集接口、模型通道、Decision抽取与统一回答	固定relore 0.3.19源码并保留许可证；完成40个生产抽取run和42次尝试；实现共享账本、理由抽取、回答器及费用对账	vendor/relore/UPSTREAM.json；historykg/llm/；historykg/extract/；deliveries/P4/2026-10-30/formal_validation.json
P5 原型与汇报	页面、状态呈现、证据交互与展示材料	完成Streamlit构建与问答界面、冻结响应重放、21项界面回归、真实页面截图及10页期末汇报材料	app/；demo/replay/flask-public-20261030.json；demo/final/期末汇报_20261030最终版.pptx
P6 参考与实验	独立参考、主题隔离、全池核验、A/B统计与图表	完成40线程参考、24题参考、48个答案和24次匿名评审；完成92/92全池两遍核验、第二仓库验收和最终预算审计	historykg/evaluation/；evaluation/results/formal_summary.json；evaluation/results/second_repo_acceptance.json

工作安排按“开发数据修复、冻结测试评价、候选统稿、成员核对与现场展示”组织。P1负责集成和材料一致性，P2/P3/P4/P5/P6分别对图查询、代码事实、模型链路、页面展示和独立实验负责；跨模块缺陷由所属角色修复，P1只做接口协调和集成验收。计划节点为11月11日期中、12月20日内部完整候选，期末实际提交日期以教师通知为准。

9.1 成员信息与贡献确认表

下表必须由六位成员本人核对和填写；空白项不表示AI已确认，也不得用Git作者名代替真实姓名。

角色	真实姓名	学号	本人核对职责与贡献	本人补充说明	签名与日期
P1	待本人填写	待本人填写	待本人核对表1对应行	待本人填写	待本人填写
P2	待本人填写	待本人填写	待本人核对表1对应行	待本人填写	待本人填写
P3	待本人填写	待本人填写	待本人核对表1对应行	待本人填写	待本人填写
P4	待本人填写	待本人填写	待本人核对表1对应行	待本人填写	待本人填写
P5	待本人填写	待本人填写	待本人核对表1对应行	待本人填写	待本人填写
P6	待本人填写	待本人填写	待本人核对表1对应行	待本人填写	待本人填写

9.2 组内互评汇总表

每格由评价人本人按1至5分填写，并在表后附至少一条可核对事实和一条改进建议；对角线不评价本人。本表只作报告汇总，不能代替课程平台要求的原始互评表，也不得由AI生成、补分或代签。

评价人 \ 被评价人	P1	P2	P3	P4	P5	P6
P1	不评价本人	待本人填写	待本人填写	待本人填写	待本人填写	待本人填写
P2	待本人填写	不评价本人	待本人填写	待本人填写	待本人填写	待本人填写
P3	待本人填写	待本人填写	不评价本人	待本人填写	待本人填写	待本人填写
P4	待本人填写	待本人填写	待本人填写	不评价本人	待本人填写	待本人填写
P5	待本人填写	待本人填写	待本人填写	待本人填写	不评价本人	待本人填写
P6	待本人填写	待本人填写	待本人填写	待本人填写	待本人填写	不评价本人

成员完成核对后，应将上述成员信息表、互评表和事实说明一并提交；在此之前，本报告只能作为期末候选，不能把空白互评视为零分、默认通过或已完成。

参考文献

[1] Hugging Face. relore: Search the decisions behind the code. https://github.com/huggingface/relore . 本项目固定源码提交06a1c99c4653e9db899a18e96d8ff0ee6b419815，版本0.3.19，访问日期2026-10-30。

[2] GitHub. Issue event types: closed. https://docs.github.com/en/rest/using-the-rest-api/issue-event-types#closed . 访问日期2026-10-30。

[3] Neo4j. Cypher Manual: Create constraints. https://neo4j.com/docs/cypher-manual/current/schema/constraints/create-constraints/ . 本项目运行版本5.26.0，访问日期2026-10-30。

[4] DeepSeek. Chat Completions API. https://api-docs.deepseek.com/zh-cn/api/create-chat-completion/ . 访问日期2026-10-30。

[5] Pallets. Flask source repository. https://github.com/pallets/flask . 具体来源、URL、作者、采集时间及哈希以冻结数据包为准。

[6] 课程项目说明：课程选题-1.pdf与课程选题_更新.pdf，选题3及报告要求，课程下发资料。

[7] 本项目P6. 正式抽取公共汇总evaluation/results/extraction_summary.json，feat/p6提交0b02114，2026-10-30。统计范围为独立模型银标，非人工金标。

[8] 本项目P6. 正式实验公共汇总evaluation/results/formal_summary.json，2026-10-30。包含抽取、A/B、全池核验与费用快照；统计范围为模型银标，非人工金标。

[9] 本项目P5. 原型系统与展示章节、正式结果验证及冻结响应 replay，2026-10-30。界面证据对应Flask作业b61942bf06b742e48860d064dffe6df2与dataset:810db3718867788c5acb0fa437cdbf62bc0f99cd8e7435e9261471225f5cd00c。

[10] Pallets. itsdangerous source repository. https://github.com/pallets/itsdangerous . 第二仓库冻结源码快照为672971d66a2ef9f85151e53283113f33d642dabd，访问日期2026-10-30。

[11] 本项目P6. 第二仓库验收evaluation/results/second_repo_acceptance.json，2026-10-30。包含347来源、30完整讨论、17文件快照、82实体、78关系、180证据及50路径依赖回答。

[12] 本项目P3. Developer与Function增量验证deliveries/P3/2026-10-30/developer_function_validation.json，2026-10-30。包含18 Developer、384 Function、20 Authored、4 Merged、384 Defines与508条证据。

[13] 本项目P6. 最终验收矩阵evaluation/results/final_acceptance.json，2026-10-30。记录92/92全池核验、零证据不足分母、预算与第二仓库验收状态。

[14] 本项目P5. 期末汇报材料说明与10页最终PPT demo/final/期末汇报_20261030最终版.pptx，2026-10-30。P1不改写P5演示文件。

[15] 本项目整合验收. 项目演化时间线evaluation/results/evolution_timeline.json及生成工具tools/build_evolution_timeline.py，2026-10-30。包含25个时间事件、5条Issue/PR/提交案例和46份逐字复核证据。