基于 relore 的开源项目历史知识图谱自动构建与可追溯问答

以 Flask 为主要实验对象的课程技术报告

2026年10月30日 · 阶段统稿 · 规划与公共契约1.4.1

说明：本文记录已实现方法和真实工程运行。正式质量实验由P6独立执行，结果发布前不填写推测指标；人员姓名与真实互评由成员本人补充。

摘要

开源项目的技术决定分散在讨论、合并记录、源码与发布说明中，普通关键词检索容易只找到其中一环。本文面向公开GitHub Python仓库，实现基于relore的有限历史自动采集、显式知识构建和有出处问答系统。系统从仓库URL出发，按统一profile选择讨论及代码快照，保存来源原文、内容哈希和证据区间；利用GitHub元数据、git与AST提取可核对事实，并通过DeepSeek抽取原子决策及其明示理由。图谱区分关闭声明与实际关闭事件、发布提及与提交可达，避免把文本共现扩大为历史事实。检索与图增强使用相同冻结来源和统一回答器，输出可追溯的原子断言。真实Flask作业已经完成采集、抽取、校验及索引发布，共形成369条来源、40个完整讨论单元、24个代码快照、133个业务实体和183条关系，其中包含61个Decision。上述数量说明实现及覆盖，不代表语义准确率。本文给出独立模型参考、抽取匹配与下游A/B实验的方法，并将工程验证、质量评测和冻结重放明确分开。正式实验结论待公开汇总发布后补入。

关键词：软件历史；知识图谱；知识抽取；证据追溯；检索增强生成

1 引言

成熟开源项目的当前代码能够说明系统怎样运行，却往往不能独立回答为什么这样设计。一项改动可能首先出现在Issue中的故障报告，经由多轮PR讨论确定方案，最终对应一个合并提交，并在稍后版本发布。开发者面对新项目时，需要跨页面、跨文件和跨版本恢复这条链。依靠记忆或单次大模型总结，很容易遗漏反对意见、混淆提议与采用状态，或把其他依赖库的决定归到当前仓库。

本项目采用课程“GitHub项目考古学家”方向，研究显式结构能否帮助组织这些分散证据。我们将任务限定为一个公开GitHub Python仓库的有限历史，不执行目标源码，不承诺采集全历史，也不训练或微调基础模型。运行资料用于回答问题；开发资料用于定位缺陷并修改程序；隔离后的测试资料用于检验冻结方法。增加资料只扩大可查询范围，不会自动更新模型权重。

relore提供项目讨论的采集、存储与历史检索基础[1]。本项目复用固定源码，新增统一来源与证据契约、自动范围选择、代码版本事实、原子Decision、显式图及公平对照接口。我们希望回答两个问题：第一，模型能否从完整讨论中抽取属于当前项目的决定和明示理由，并给出可复算证据；第二，在同来源、同模型和同上下文预算下，图路径扩展是否改善跨来源问答，以及它在什么情形下引入

噪声。两者都需要真实实验，不能由页面可运行或图节点数量代替。

前期独立小样曾真实接通技术链路，但暴露了依赖库归属错误、理由漏抽和显式链接漏采。因此后续实现围绕具体失败收紧证据条件，而没有以旧小样成功宣称课程项目完成。旧主题被登记为开发资料，不再冒充正式盲测。这种区分使工程修复与实验评价各自回答明确的问题。

2 数据集与知识图谱构造

2.1 自动范围与多源资料

使用者完成账号、数据库和费用配置后，只输入仓库URL。程序检查公开可读和Python支持，拒绝不在范围内的输入。默认course_small_v1最多读取100条PR候选和100条Issue候选，按更新时间及编号稳定排序，优先已合并PR和显式关联Issue，再补近期Issue。讨论单元总上限为40，不要求人工选择案例或补编号。显式关联补采同样占配额，仓库外引用只留下缺口，不启动跨仓库联合图。

一个完整讨论单元包含正文、全部分页普通评论、PR评审主体和行内评论及回复。不存在的类别记已确认空，未读到的页记缺失；不能因为正文已经取得，就把线程标为完整。程序记录端点、分页游标、失败与重试，请求达到上限后保存可恢复状态。有限采样本身不等于partial，实际未读分页或抽取失败才构成不完整。

代码模块根据已选PR自动定位合并提交、第一父提交和Python变化文件，最多检查40个相关提交、24个文件乘SHA状态和3个发布记录。在24个状态内预留有限默认分支包入口及一层内部依赖，以便回答模块职责；这一规则不读取测试问题。无正式Release时有限回退到tag，并说明接口顺序不等于发布时间；浅历史无法证明的可达性保留unknown。

真实Flask运行只输入pallets/flask仓库URL，没有手填线程、SHA或路径。冻结来源池共有369条SourceDocument、40个complete讨论单元和24个代码快照。来源包括API元数据、git输出、源码、发布说明、提交说明以及讨论正文和评论。网络累计182次，包含失败、重试与git网络操作，不能只以成功线程数代表网络成本。该范围是一次有限自动池，不是Flask全历史。

公开来源	完整讨论	代码快照	实体 / 关系	Decision
369	40	24	133 / 183	61

2.2 冻结、稳定身份与证据

每个数据集在写首条来源前，由规范仓库、profile版本和job身份生成dataset_id；内容哈希另外保存，不循环参与身份计算。来源仅统一换行为LF，其余文字保持原样；source_id包含origin_key和文本哈希。API对象保存一份固定UTF-8 JSON表示，明确其为规范化对象而非逐字HTTP正文，保留非敏感GET端点、参数及状态，不保存认证头。

Evidence以source_id、start、end和quote表示，偏移为Unicode码点的零起始、左闭右开区间，程序要求text[start:end]与quote逐字相等。中文、emoji与重复引文均可能导致位置错误，因此重复引文

必须借助明确位置或邻近上下文消歧，浏览器不能用UTF-16自行重算。URL用于跳转，冻结原文、哈希和位置用于复算；网页后续变化不应改变本次证据。

manifest保存文件与来源哈希、采集范围、版本、完整性和缺口。当前生产包的应用执行版本在发布后依主运行记录核对并补为独立exports元数据，明确补记时间与适用阶段，原manifest及已发布图指纹保持不变，不能声称完整应用SHA在采集前已经记录。后续build直接保存各阶段实际应用SHA、工作树状态及代码文件哈希，避免把relore上游版本误当作本组程序版本。

2.3 显式模式与关系语义

图的业务实体限定为Project、Issue、PullRequest、Commit、File、Release和Decision。File代表特定提交下的文件快照，同路径不同SHA不合并；Release由仓库与原样tag确定，同提交不同tag也不合并。普通评论和API响应作为来源保存，不再为每条评论创建业务实体。Decision保存主体、动作、采用状态、结论、理由及各自证据，通过ABOUT和EVIDENCED_BY连接主体及来源。

关系条件由证据性质决定。PR文字中的Fixes或Closes生成ClaimsToClose，只有官方关闭事件能够核对当前仓库对象并关联该PR或其已确认合并SHA时，才接受Closes。GitHub文档区分历史关闭事件和当前状态[2]，因此仅有merged、closed或同号提及均不够。MergedAs表示PR合并提交，Touches表示提交触及文件，ChangesTo连接明确前后文件，Imports只连接同SHA且已取得的内部目标。MentionsPR表示发布说明提及，ReachableIn表示提交对tag可达，两者都不直接证明首次发布或修复成功。

导入Neo4j前检查稳定ID、端点、关系方向、证据、仓库和dataset归属，错误使整批拒收。图库使用dataset与id组合约束[3]，全部遍历带数据集过滤，防止同号Issue或跨库实体串连。相同冻结包重复导入后读回全部记录并比较指纹；同一dataset内容变化则拒收，要求新版本。当前生产结果为133个业务实体、183条关系、333条证据，61个Decision已包含于133实体，不能重复相加。

3 任务定义

知识抽取输入是一个完整讨论单元及可见主体目录，输出是原子Decision集合。模型需判定对象属于哪个仓库、讨论采取什么动作、状态是proposed、accepted还是rejected，并单独抽取原文明示理由。没有理由不要求模型补出“合理解释”；无法唯一映射主体的候选保留unresolved，依赖库决定保留external_project，不强挂本地实体。

下游输入是一条自然语言问题和已发布数据集。系统输出原子claims、证据、真实路径与缺口。claims中每项结论必须能回到最终上下文的原文片段，不允许额外生成未经校验的summary。search、trace、timeline、dependencies和compare共享接口，后两类在采样范围缺资料时可返回unsupported。状态分别表达成功、无支持材料、不支持和运行错误；断库或模型失败不能计为正确弃答。

我们把显式图的作用限定为组织和扩展证据。它使“讨论理由、PR、提交、文件”能够通过已有边串联，但不会制造缺失关系或让回答器知道未采事实。因此跨来源回答应同时给出相关片段及路径，不能只展示一张关系图就宣称完成多跳推理。尤其“提交发生过”“发布提及过”和“功能真正修复”属于不同强度的结论。

4 系统方法

4.1 唯一流水线与恢复

系统由Python3.11实现，阶段依次为discover、collect、code、extract、validate和index_graph。P1维护唯一持久作业及公共CLI，P3提供代码事实，P4提供采集器、抽取和回答，P2提供图与检索，P5只调用构建与查询接口。页面刷新复用活跃job，不产生另一套编排；进程退出后显式resume检查已完成阶段哈希，只重试尚未完成阶段。

作业保存请求、配置快照、阶段结果、覆盖、用量和失败。单worker采用操作系统文件锁，进程退出后系统释放占用，空锁文件也可恢复。只有真实LLM抽取、公共校验、图和共同检索均完成，才发布ready或partial。ready说明约定有限范围内各阶段完成，不表示知识全对或资料全量。预算不足、凭据缺失及可恢复外部限制为blocked；失败时保留已有原文和检查点，不能偷偷重爬或重复付费。

4.2 固定代码与静态演化事实

P4保留relore 0.3.19固定提交06a1c99c4653e9db899a18e96d8ff0ee6b419815的源码、许可证与来源记录。采集、线程存储和词法检索复用上游能力，项目适配层负责URL、选单、冻结回放与公共记录映射。报告把上游已有能力和本组新增代码分开记载，不将开源移植等同于重新发明检索器。

P3只静态读取目标git对象，不安装或执行历史源码。程序用diff识别增加、修改、删除、改名与复制，删除指向父版本实际文件。AST提取静态import和顶层定义，字节列偏移转换为公共码点偏移；外部依赖、未采目标、读取失败和解析失败单列缺口。静态import不等于运行调用图，24份快照也不支持任意API或全项目职责判断。

4.3 结构化模型抽取与用量

生产使用DeepSeek API，实际请求明确设置deepseek-flash、thinking disabled、temperature 0、max_tokens 4096、最大2次重试、200000输入字节上限和90秒超时。讨论按最多20000码点分块，邻块保留400码点重叠；每块保存覆盖及run_id。模型返回Schema约束候选和逐字引文，程序完成主体映射、证据定位和稳定身份赋值，不要求模型猜URL或编实体ID。

共享网关保存输入、实际配置、提示版本、Schema、原始响应、结束原因和每次尝试。API成功但length截断、空输出、JSON或引文校验失败均不算成功[4]。重试最多两次，失败仍占用预算并保留；同一run由输入、模型参数、提示和repeat_index共同确定，缓存重放不发新请求，改变方法不能冒用旧缓存效果。reference和judge从首次请求起进入P6私有目录，生产任务拒绝该路径。

真实生产抽取有40个run和42次尝试，包含重试，累计621615输入token与24717输出token。旧manifest中的model_requests=0来自代码阶段局部值，不代表全流程零模型调用。用量导出分别列阶段、新增、复用和累计attempt；历史record中的1.440966元为当时保守上界，实际核算采用P4共享账本及其公开对账结果。整个项目共用已批10元上限，因可用余额有效上限降至9.84元，不按角色或数据集重开额度。

4.4 同源检索与图增强

每个数据集在PostgreSQL建立独立冻结relore空间，从已保存ThreadPayload无网络回放，并核对来源映射。后续同仓库重新采集不会改变旧数据集检索结果。共同适配层让发布说明、提交说明、源码、git输出和API响应与讨论一样可被固定词法检索，按source_id稳定打破同分，并与真实relore排序作固定排名融合。

A组使用共同检索种子和统一回答器，B组在同样种子上扩展最多三跳图路径，再使用同一回答器。主体解析由编号、URL、目录及检索结果共同完成，不要求用户复制内部ID。两组均按同一渲染规则去重、排序和截断，最终上下文上限为12000个Unicode码点，标题及结构字段占预算。裁剪同步修改区间与quote，并保留最终实际送入模型的文本，而不是只保存截断前候选。

这种设计将方法差异限定为图扩展。A不能只读讨论而让B独占源码或发布文本，也不能给B额外来源。图扩展可能补齐跨源环节，也可能用相关但无用的片段挤占上下文，因此其收益必须由最终可见证据和回答共同评估，不能由路径更多直接推断。

5 实验设计与当前结果状态

5.1 独立参考与隔离

正式实验由P6在来源冻结后独立控制。规划的讨论样本为40个完整单元，按主题划分10开发、30测试；代码为12个文件乘SHA样本，4开发、8测试；下游24题，4开发、20测试。生产池有24份快照，但不能把它们全部混称正式12个代码样本。跨线程同主题必须分到同组，已看过并用于修复的旧主题保持开发身份。实际实验分母、排除和覆盖以P6最终协议及原表为准。

参考生成覆盖完整原文，包含生产没有抽到的事实，不能只检查已有Decision。模型参考与独立复核都保存请求、输出和分歧，称为模型参考或银标，不宣称人工金标。下游问题在冻结来源后生成，测试生产输入仅含问题身份及正文，不带答案、题型、来源提示或可回答标签。测试参考、盲化映射和评分不会进入图、检索或开发调参材料。

证据不足题必须对整个冻结可检索池核验，单个主题没有答案不够。定位修复、决策理由和版本代码关联中保留跨源覆盖，并至少包含一题有源码依据的有限模块职责或依赖实答。第二小库只用于换URL免改代码检查，不追加另一套正式参考或以单次迁移声称任意仓库通用。

5.2 指标与公平对照

抽取按参考与预测一对一匹配得到TP、FP、FN，报告Precision、Recall和F1。重复预测计FP，完整漏抽计FN，有应抽事实而全漏时F1为0；分母为零记N/A。理由指标以参考中明确stated且有效的决定为分母，漏整条、空理由和部分理由均不能从分母消失。除总分外，分别报告归属、状态、理由和引用错误。

代码实验只报告冻结快照范围内的正确、错误、unknown及解析失败，不在缺少完整事件参考时报告事件召回。下游报告原子事实覆盖、证据组召回、无依据断言率、正确弃答率、延迟及token费用。必要的不同环节分为不同证据组，组内替代片段只计一次；召回按最终prompt中完整可见区间计

算，候选命中、节点名和最终引用都不能替代这一口径。

评审覆盖全部返回claims，包括没有引文的断言。unsupported断言除以全部断言构成无依据断言率，unclear另列。模型或服务失败不视为正确弃答，可回答题中的失败或空输出记零覆盖；若评审重试后仍漏项，总体指标记N/A并单列已评子集和覆盖。两组使用同一问题、原文池、模型、提示、参数、上下文预算和盲化评审，报告胜例、败例与无差异，不预设图谱胜出。

5.3 工程结果与待填质量结果

当前真实URL作业已完成全部六阶段并发布ready，actual_llm_extraction、graph_ready和retrieval_ready均为true。公共来源、证据及端点检查通过；图记录从冻结文件构建并读回校验。主代理独立复跑过受影响的公共流水线、模型、图查询和界面检查。这些证据证明模块可协同运行，不能写成抽取准确率，也不能用某个开发问题的成功回答代替A/B总体结论。

本报告编制时，正式抽取匹配、全池不足证据核验和A/B评分仍由P6执行。Precision、Recall、F1、理由完整率以及下游指标暂记未发布，后续仅从公开统计文件重算并填入。完整原文参考40单元的覆盖完成，与正式评分全部完成是不同状态。第二库、跨源实答和架构实答也分别要求真实运行记录，未获得记录的条目保持待验收。

Windows验证使用GitHub托管windows-2022环境安装锁定Python依赖，并启动原生PostgreSQL16.4及Neo4j5.26.0，重建合成fixture和公开Flask冻结包。macOS已用同一脚本完成真实冻结包重复导入与检索。Windows的最终CI结果在运行结束后补入；该流程不配置模型密钥，不是Windows在线抽取或同学本机实测，缓存与重放均显式标记。

6 原型系统与使用展示

原型采用Streamlit单页面，按“提交仓库、观察构建、围绕已采历史提问”组织。安装者一次配置数据库、GitHub只读访问、DeepSeek密钥与共享预算后，使用者只需输入公开仓库链接。页面调用start_build、get_build和resume_build，显示后端真实阶段、完整单元、来源数和快照数。作业与dataset内部身份放入诊断区，避免让普通用户选择技术路径。

queued、running、blocked、failed和unsupported均不开放问答，只有ready或partial允许输入问题；partial持续展示缺口。页面重绘不重建任务，同一次响应保存在会话中，避免刷新重复调用模型。暂停或失败通过显式恢复入口接续检查点，不要求使用者重新选材料。界面不以“已抓到若干来源”代替“可查询图已发布”。

答案按顺序呈现全部claims.text，每项链接到相应证据，包含原文、来源URL、作者时间、版本与位置。关系链来自公共查询结果，不由页面临时推断或美化；没有Decision时仍可呈现已有PR、提交及文件链。empty、unsupported和error分别解释资料不足、范围限制和调用故障。课堂备份模式读取带原运行时间的真实缓存，清楚标为重放并关闭在线输入，不能将重放计作在线时延。

可用开发例是Flask PR6133：本地测试调整的明示理由是适应尚未发布的Werkzeug。修复后的抽取保留本地决定及理由，同时将Werkzeug新增client.query识别为外库候选，不挂到Flask主体；回答器

输出带逐字引文的claims。该例属于已登记开发回归，说明具体问题怎样被发现和修正，不进入正式测试成绩，也不替代仅URL的产品验收。

7 复现、费用与局限

复现分三个层次。第一层使用已保存评分和统计代码重算数字，不再请求模型；第二层使用冻结来源、图记录和relore输入重建数据库与页面，验证哈希、幂等性及检索；第三层重新调用外部模型，要求使用者自己的账号、密钥和额度，并承认别名、服务版本及随机性可能导致输出不同。交付锁定依赖、固定上游、源码、公开冻结包、模型记录及实验归档，私有参考由P6在正式结束后按课程范围发布。

本次公开最小重建包保存原manifest和18份带哈希JSONL，以及无网络检索回放输入。它不包含密钥、个人配置、完整clone或私有测试。未来源码变更与已有生产运行分别记录，不能用当前HEAD假装过去的执行版本。原manifest中历史个人capture路径仅作原运行出处记录，重建读取包内相对路径，无需原电脑目录。

费用由唯一SQLite账本以整数微元控制，请求前预留上界，失败和重试不消失。P4根据实际时段与缓存命中元数据对账，原保守记录仍保留历史语义；报告分别列批准上限、账本核算额、未知用量上界和提供商余额。余额下降与账本总额可能受观测时间影响，不据此擅自提高预算。P1的冻结重建及统计重算均不产生新增模型请求。

方法存在四项实际局限。首先，有限近期采样无法恢复全生命周期，未采发布或文件不能凭空回答。其次，静态AST只提供局部依赖事实，动态导入与运行行为不在当前范围。再次，模型可能把观点误判为决定、遗漏理由或在引文真实时仍作出错误归属，格式和偏移校验不能证明语义正确。最后，独立模型参考与judge仍可能共享偏差，银标结果需要结合覆盖及分歧解释。图谱将这些信息显式组织，但不会自动消除错误。

8 结论与后续工作

项目已将公开仓库URL、完整讨论采集、有限代码事实、真实模型抽取、显式图和同源检索接入一个可恢复流程。统一证据契约使讨论、API、git与源码能够使用同一套原文位置复算，关系语义则限制了从文本声明到历史事实的无依据升级。真实Flask生产作业证明这条有限流程可以执行并发布，冻结包支持无新增模型请求的重建。

显式图的实际价值仍以独立抽取和公平A/B实验为准。后续完成正式评分、第二库自动检查及真实跨源与职责实答后，将公开统计和失败分析并入本文，不根据分数修改冻结来源或删除难例。期中以五分钟说明问题、方法和已运行事实，期末交付完整PDF、两次PPT、代码数据及复现材料；真实成员互评与课堂表达由本人完成。

9 人员与工作安排及组内互评

P1负责公共数据、ID与IO、URL发现、唯一作业编排、冻结及总集成，承担报告统稿、跨平台与复现包。P2负责图模式的可执行导入、Neo4j、同源检索隔离及公共查询。P3负责自动提交与文件定位、版本和静态代码事实。P5负责页面、状态呈现、证据交互及期中期末展示材料。P6独立负责参考、主题隔离、评分、正式统计与第二库检查，不向生产侧提供测试答案。

P4的累计贡献包含前期独立调研、总体方案起草、多轮架构迭代、统一规划及协作框架、期初独立原型与小规模真实试跑，后续继续完成固定relore移植、基础采集存储检索接口、共享模型通道、Decision与理由抽取、统一回答器和费用对账。这些前期工作不因后续模块接收而转记给集成者。六个角色的工程实现和材料准备由各自AI在授权下执行，成员贡献归属依据真实工作记录，不能用AI目录或章节字数伪造人工作时。

成员姓名、学号及正式互评尚未收齐，本稿保留角色标识。最终需由六位成员亲自核对自己的实际参与，并填写对组内协作、任务承担和沟通的真实评价；本文不自动给分、代签或推断他人态度。计划节点为11月11日期中、12月20日内部完整候选，期末实际提交日期仍以教师通知为准。

参考文献

[1] Hugging Face. relore: Search the decisions behind the code. https://github.com/huggingface/relore . 本项目固定源码提交06a1c99c4653e9db899a18e96d8ff0ee6b419815，版本0.3.19，访问日期2026-10-30。

[2] GitHub. Issue event types: closed. https://docs.github.com/en/rest/using-the-rest-api/issue-event-types#closed . 访问日期2026-10-30。

[3] Neo4j. Cypher Manual: Create constraints. https://neo4j.com/docs/cypher-manual/current/schema/constraints/create-constraints/ . 本项目运行版本5.26.0，访问日期2026-10-30。

[4] DeepSeek. Chat Completions API. https://api-docs.deepseek.com/zh-cn/api/create-chat-completion/ . 访问日期2026-10-30。

[5] Pallets. Flask source repository. https://github.com/pallets/flask . 具体来源、URL、作者、采集时间及哈希以冻结数据包为准。

[6] 课程项目说明：课程选题_更新.pdf，选题3及报告要求，课程下发资料。