# 基于 relore 的开源项目历史知识图谱自动构建与可追溯问答

## 以 Flask 为主要实验对象的课程技术报告

2026年10月30日 · 期末统稿 · 规划与公共契约1.4.1

说明：本文记录已实现方法、真实工程运行、正式抽取实验、下游A/B、全池核验和第二仓库迁移结果。统计相对独立模型银标，不冒充人工金标；人员姓名、学号与组内互评保留为“待本人补充”，不由AI代填。

## 摘要

开源项目的技术决定分散在讨论、合并记录、源码与发布说明中，普通关键词检索容易只找到其中一环。本文面向公开GitHub Python仓库，实现基于relore的有限历史自动采集、显式知识构建和有出处问答系统。系统从仓库URL出发，按统一profile选择讨论及代码快照，保存来源原文、内容哈希和证据区间；利用GitHub元数据、git与AST提取可核对事实，并通过DeepSeek抽取原子决策及其明示理由。图谱区分关闭声明与实际关闭事件、发布提及与提交可达，避免把文本共现扩大为历史事实。检索与图增强使用相同冻结来源和统一回答器，输出可追溯的原子断言。真实Flask作业已经完成采集、抽取、校验及索引发布，共形成369条来源、40个完整讨论单元、24个代码快照、133个业务实体和183条关系，其中包含61个Decision。代码侧只读增量分片另生成18个Developer、384个Function、20条Authored、4条Merged和384条Defines关系，508条证据均通过原文区间复核。相对独立模型银标，30个测试单元的抽取Precision为0.5682、Recall为0.9615、F1为0.7143，明示理由完整覆盖13/15。下游实验保存24道题的48个A/B答案，并由24次匿名评审覆盖全部claims；20道测试题上，A/B事实覆盖分别为0.600和0.740，配对平均差为0.157，但固定种子95%描述性bootstrap区间[-0.122, 0.457]跨零，因此不宣称显著收益。全池92个位置完成两遍核验，6个首次失败位置经一次格式恢复重试后全部成功；6道候选均未确认证据不足，正确弃答率因合格分母为0而记为N/A。同一入口在pallets/itsdangerous上生成347条来源、30个完整讨论、17个文件快照、82个实体、78条关系和180条证据，依赖问题返回50条路径、25条证据和5条可核出处claims，但因采集缺口保持partial。该统计衡量银标一致性，不能视为人工金标准确率。

关键词：软件历史；知识图谱；知识抽取；证据追溯；检索增强生成

## 1 引言

成熟开源项目的当前代码能够说明系统怎样运行，却往往不能独立回答为什么这样设计。一项改动可能首先出现在Issue中的故障报告，经由多轮PR讨论确定方案，最终对应一个合并提交，并在稍后版本发布。开发者面对新项目时，需要跨页面、跨文件和跨版本恢复这条链。依靠记忆或单次大模型总结，很容易遗漏反对意见、混淆提议与采用状态，或把其他依赖库的决定归到当前仓库。

本项目采用课程“GitHub项目考古学家”方向，研究显式结构能否帮助组织这些分散证据。我们将任务限定为一个公开GitHub Python仓库的有限历史，不执行目标源码，不承诺采集全历史，也不训

练或微调基础模型。运行资料用于回答问题；开发资料用于定位缺陷并修改程序；隔离后的测试资料用于检验冻结方法。增加资料只扩大可查询范围，不会自动更新模型权重。

relore提供项目讨论的采集、存储与历史检索基础[1]。本项目复用固定源码，新增统一来源与证据契约、自动范围选择、代码版本事实、原子Decision、显式图及公平对照接口。我们希望回答两个问题：第一，模型能否从完整讨论中抽取属于当前项目的决定和明示理由，并给出可复算证据；第二，在同来源、同模型和同上下文预算下，图路径扩展是否改善跨来源问答，以及它在什么情形下引入噪声。两者都需要真实实验，不能由页面可运行或图节点数量代替。

前期独立小样曾真实接通技术链路，但暴露了依赖库归属错误、理由漏抽和显式链接漏采。因此后续实现围绕具体失败收紧证据条件，而没有以旧小样成功宣称课程项目完成。旧主题被登记为开发资料，不再冒充正式盲测。这种区分使工程修复与实验评价各自回答明确的问题。

# 2 数据集与知识图谱构造

## 2.1 自动范围与多源资料

使用者完成账号、数据库和费用配置后，只输入仓库URL。程序检查公开可读和Python支持，拒绝不在范围内的输入。默认course_small_v1最多读取100条PR候选和100条Issue候选，按更新时间及编号稳定排序，优先已合并PR和显式关联Issue，再补近期Issue。讨论单元总上限为40，不要求人工选择案例或补编号。显式关联补采同样占配额，仓库外引用只留下缺口，不启动跨仓库联合图。

一个完整讨论单元包含正文、全部分页普通评论、PR评审主体和行内评论及回复。不存在的类别记已确认空，未读到的页记缺失；不能因为正文已经取得，就把线程标为完整。程序记录端点、分页游标、失败与重试，请求达到上限后保存可恢复状态。有限采样本身不等于partial，实际未读分页或抽取失败才构成不完整。

代码模块根据已选PR自动定位合并提交、第一父提交和Python变化文件，最多检查40个相关提交、24个文件乘SHA状态和3个发布记录。在24个状态内预留有限默认分支包入口及一层内部依赖，以便回答模块职责；这一规则不读取测试问题。无正式Release时有限回退到tag，并说明接口顺序不等于发布时间；浅历史无法证明的可达性保留unknown。

真实Flask运行只输入pallets/flask仓库URL，没有手填线程、SHA或路径。冻结来源池共有369条SourceDocument、40个complete讨论单元和24个代码快照。来源包括API元数据、git输出、源码、发布说明、提交说明以及讨论正文和评论。网络累计182次，包含失败、重试与git网络操作，不能只以成功线程数代表网络成本。该范围是一次有限自动池，不是Flask全历史。

| 公开来源 | 完整讨论 | 代码快照 | 实体 / 关系 | Decision |
| --- | --- | --- | --- | --- |
| 369 | 40 | 24 | 133 / 183 | 61 |

第二仓库使用pallets/itsdangerous[10]，只输入公开仓库URL，沿用course_small_v1及同一流水线，没有手选线程、SHA、路径或补图。作业ebfd8c8dae5e4bcf998a79fef35de981形成347条来源、30个完

整讨论单元、17个文件快照、82个实体、78条关系和180条证据，validate、graph与retrieval均为ready。采集保留10次HTTP 404、147个未补采显式引用以及外部目标和发布可达性缺口，因此作业状态诚实记为partial，success不等于全历史完整。依赖查询返回50条路径、25条证据和5条claims，所有引用ID可解析，引文逐字匹配冻结源码并复算SHA-256；另一条search查询为empty，也原样保留。该结果证明一次受限迁移和可追溯回答，不外推为任意Python仓库均可用。

## 2.2 冻结、稳定身份与证据

每个数据集在写首条来源前，由规范仓库、profile版本和job身份生成dataset_id；内容哈希另外保存，不循环参与身份计算。来源仅统一换行为LF，其余文字保持原样；source_id包含origin_key和文本哈希。API对象保存一份固定UTF-8 JSON表示，明确其为规范化对象而非逐字HTTP正文，保留非敏感GET端点、参数及状态，不保存认证头。

Evidence以source_id、start、end和quote表示，偏移为Unicode码点的零起始、左闭右开区间，程序要求text[start:end]与quote逐字相等。中文、emoji与重复引文均可能导致位置错误，因此重复引文必须借助明确位置或邻近上下文消歧，浏览器不能用UTF-16自行重算。URL用于跳转，冻结原文、哈希和位置用于复算；网页后续变化不应改变本次证据。

manifest保存文件与来源哈希、采集范围、版本、完整性和缺口。当前生产包的应用执行版本在发布后依主运行记录核对并补为独立exports元数据，明确补记时间与适用阶段，原manifest及已发布图指纹保持不变，不能声称完整应用SHA在采集前已经记录。后续build直接保存各阶段实际应用SHA、工作树状态及代码文件哈希，避免把relore上游版本误当作本组程序版本。

## 2.3 显式模式与关系语义

图的业务实体限定为Project、Issue、PullRequest、Commit、File、Release和Decision。File代表特定提交下的文件快照，同路径不同SHA不合并；Release由仓库与原样tag确定，同提交不同tag也不合并。普通评论和API响应作为来源保存，不再为每条评论创建业务实体。Decision保存主体、动作、采用状态、结论、理由及各自证据，通过ABOUT和EVIDENCED_BY连接主体及来源。

关系条件由证据性质决定。PR文字中的Fixes或Closes生成ClaimsToClose，只有官方关闭事件能够核对当前仓库对象并关联该PR或其已确认合并SHA时，才接受Closes。GitHub文档区分历史关闭事件和当前状态[2]，因此仅有merged、closed或同号提及均不够。MergedAs表示PR合并提交，Touches表示提交触及文件，ChangesTo连接明确前后文件，Imports只连接同SHA且已取得的内部目标。MentionsPR表示发布说明提及，ReachableIn表示提交对tag可达，两者都不直接证明首次发布或修复成功。

导入Neo4j前检查稳定ID、端点、关系方向、证据、仓库和dataset归属，错误使整批拒收。图库使用dataset与id组合约束[3]，全部遍历带数据集过滤，防止同号Issue或跨库实体串连。相同冻结包重复导入后读回全部记录并比较指纹；同一dataset内容变化则拒收，要求新版本。当前Flask生产结果为133个业务实体、183条关系、333条证据，61个Decision已包含于133实体，不能重复相加。

P3的Developer与Function属于新的只读增量分片，不向旧1.4.1生产图原地补写，因此不能把18个Developer、384个Function和508条证据直接加到上述生产计数。Developer只取自PR API顶层user和merged_by，不读取Commit author；Authored和Merged均连接Developer与PullRequest，Defines连接同SHA的File与Function。系统没有Developer→Commit边，避免将提交作者误推为PR作者或合并者。PullRequest→Commit仍由P1的MergedAs事实表达。

# 3 任务定义

知识抽取输入是一个完整讨论单元及可见主体目录，输出是原子Decision集合。模型需判定对象属于哪个仓库、讨论采取什么动作、状态是proposed、accepted还是rejected，并单独抽取原文明示理由。没有理由不要求模型补出“合理解释”；无法唯一映射主体的候选保留unresolved，依赖库决定保留external_project，不强挂本地实体。

下游输入是一条自然语言问题和已发布数据集。系统输出原子claims、证据、真实路径与缺口。claims中每项结论必须能回到最终上下文的原文片段，不允许额外生成未经校验的summary。search、trace、timeline、dependencies和compare共享接口，后两类在采样范围缺资料时可返回unsupported。状态分别表达成功、无支持材料、不支持和运行错误；断库或模型失败不能计为正确弃答。

我们把显式图的作用限定为组织和扩展证据。它使“讨论理由、PR、提交、文件”能够通过已有边串联，但不会制造缺失关系或让回答器知道未采事实。因此跨来源回答应同时给出相关片段及路径，不能只展示一张关系图就宣称完成多跳推理。尤其“提交发生过”“发布提及过”和“功能真正修复”属于不同强度的结论。

# 4 系统方法

## 4.1 唯一流水线与恢复

系统由Python3.11实现，阶段依次为discover、collect、code、extract、validate和index_graph。P1维护唯一持久作业及公共CLI，P3提供代码事实，P4提供采集器、抽取和回答，P2提供图与检索，P5只调用构建与查询接口。页面刷新复用活跃job，不产生另一套编排；进程退出后显式resume检查已完成阶段哈希，只重试尚未完成阶段。

作业保存请求、配置快照、阶段结果、覆盖、用量和失败。单worker采用操作系统文件锁，进程退出后系统释放占用，空锁文件也可恢复。只有真实LLM抽取、公共校验、图和共同检索均完成，才发布ready或partial。ready说明约定有限范围内各阶段完成，不表示知识全对或资料全量。预算不足、凭据缺失及可恢复外部限制为blocked；失败时保留已有原文和检查点，不能偷偷重爬或重复付费。

## 4.2 固定代码与静态演化事实

P4保留relore 0.3.19固定提交06a1c99c4653e9db899a18e96d8ff0ee6b419815的源码、许可证与来源记录。采集、线程存储和词法检索复用上游能力，项目适配层负责URL、选单、冻结回放与公共记录映射。报告把上游已有能力和本组新增代码分开记载，不将开源移植等同于重新发明检索器。

P3只静态读取目标git对象，不安装或执行历史源码。程序用diff识别增加、修改、删除、改名与复制，删除指向父版本实际文件。AST提取静态import和顶层定义，字节列偏移转换为公共码点偏移；外部依赖、未采目标、读取失败和解析失败单列缺口。静态import不等于运行调用图，24份快照也不支持任意API或全项目职责判断。

新增事实从PR API顶层user与merged_by提取Developer，并从24个文件乘SHA快照的顶层FunctionDef/AsyncFunctionDef提取Function。实测只读分片得到18个Developer、384个Function、20条Authored、4条Merged和384条Defines关系，全部508条证据均通过Unicode原文区间检查；ClassDef和方法不计入Function，两次重放稳定ID一致。固定链已核对为PR #6096（作者lkk7、合并者davidism）→提交05e9c6bd630ecf4ec0ec884b1fc7901663737bc7→src/flask/testing.py→flask.testing._get_werkzeug_version，函数位于第100至106行。PR→提交边沿用已有MergedAs，P3不生成Developer→Commit。公开验证见[12]。

## 4.3 结构化模型抽取与用量

生产使用DeepSeek API，实际请求明确设置deepseek-flash、thinking disabled、temperature 0、max_tokens 4096、最大2次重试、200000输入字节上限和90秒超时。讨论按最多20000码点分块，邻块保留400码点重叠；每块保存覆盖及run_id。模型返回Schema约束候选和逐字引文，程序完成主体映射、证据定位和稳定身份赋值，不要求模型猜URL或编实体ID。

共享网关保存输入、实际配置、提示版本、Schema、原始响应、结束原因和每次尝试。API成功但length截断、空输出、JSON或引文校验失败均不算成功[4]。重试最多两次，失败仍占用预算并保留；同一run由输入、模型参数、提示和repeat_index共同确定，缓存重放不发新请求，改变方法不能冒用旧缓存效果。reference和judge从首次请求起进入P6私有目录，生产任务拒绝该路径。

真实生产抽取有40个run和42次尝试，包含重试，累计621615输入token与24717输出token。旧manifest中的model_requests=0来自代码阶段局部值，不代表全流程零模型调用。用量导出分别列阶段、新增、复用和累计attempt；历史record中的1.440966元为当时保守上界，按42个生产attempt身份在P4共享账本只读核对，核算为0.657140元，未知用量上界为0；不混入开发抽取或参考评审费用。最终共享账本保留同一历史序列，没有重置：approved=20元、effective cap=19.84元，387次attempt中362次settled、25次uncertain，保守累计9.465795元，由known usage 7.771385元和unknown upper 1.694410元组成，余10.374205元。本轮新增1.092283元，其中第二仓库0.589461元、全池失败位置格式恢复重试0.502822元。

## 4.4 同源检索与图增强

每个数据集在PostgreSQL建立独立冻结relore空间，从已保存ThreadPayload无网络回放，并核对来源映射。后续同仓库重新采集不会改变旧数据集检索结果。共同适配层让发布说明、提交说明、源码、git输出和API响应与讨论一样可被固定词法检索，按source_id稳定打破同分，并与真实relore排序作固定排名融合。

A组使用共同检索种子和统一回答器，B组在同样种子上扩展最多三跳图路径，再使用同一回答器。主体解析由编号、URL、目录及检索结果共同完成，不要求用户复制内部ID。两组均按同一宣

染规则去重、排序和截断，最终上下文上限为12000个Unicode码点，标题及结构字段占预算。裁剪同步修改区间与quote，并保留最终实际送入模型的文本，而不是只保存截断前候选。

这种设计将方法差异限定为图扩展。A不能只读讨论而让B独占源码或发布文本，也不能给B额外来源。图扩展可能补齐跨源环节，也可能用相关但无用的片段挤占上下文，因此其收益必须由最终可见证据和回答共同评估，不能由路径更多直接推断。

# 5 实验设计与正式结果

## 5.1 独立参考与隔离

正式实验由P6在来源冻结后独立控制。讨论样本为40个完整单元，按主题划分10开发、30测试；代码为12个文件乘SHA样本，4开发、8测试；下游24题，4开发、20测试。生产池有24份快照，但不能把它们全部混称正式12个代码样本。跨线程同主题必须分到同组，已看过并用于修复的旧主题保持开发身份。正式结果按冻结协议、固定分母和公开汇总报告，不根据事后结果删除题目或改写参考。

参考生成覆盖完整原文，包含生产没有抽到的事实，不能只检查已有Decision。模型参考与独立复核都保存请求、输出和分歧，称为模型参考或银标，不宣称人工金标。下游问题在冻结来源后生成，测试生产输入仅含问题身份及正文，不带答案、题型、来源提示或可回答标签。测试参考、盲化映射和评分不会进入图、检索或开发调参材料。

证据不足题必须对整个冻结可检索池核验，单个主题没有答案不够。定位修复、决策理由和版本代码关联中保留跨源覆盖，并至少包含一题有源码依据的有限模块职责或依赖实答。第二仓库只用于换URL免改代码检查，不追加另一套正式参考，也不以单次迁移声称任意仓库通用。

## 5.2 指标与公平对照

抽取按参考与预测一对一匹配得到TP、FP、FN，报告Precision、Recall和F1。重复预测计FP，完整漏抽计FN，有应抽事实而全漏时F1为0；分母为零记N/A。理由指标以参考中明确stated且有效的决定为分母，漏整条、空理由和部分理由均不能从分母消失。除总分外，分别报告归属、状态、理由和引用错误。

代码实验只报告冻结快照范围内的正确、错误、unknown及解析失败，不在缺少完整事件参考时报告事件召回。下游报告原子事实覆盖、证据组召回、无依据断言率、正确弃答率、延迟及token费用。必要的不同环节分为不同证据组，组内替代片段只计一次；召回按最终prompt中完整可见区间计算，候选命中、节点名和最终引用都不能替代这一口径。

评审覆盖全部返回claims，包括没有引文的断言。unsupported断言除以全部断言构成无依据断言率，unclear另列。模型或服务失败不视为正确弃答，可回答题中的失败或空输出记零覆盖；若评审重试后仍漏项，总体指标记N/A并单列已评子集和覆盖。两组使用同一问题、原文池、模型、提示、参数、上下文预算和盲化评审，报告胜例、败例与无差异，不预设图谱胜出。

## 5.3 工程与正式抽取结果

当前真实URL作业已完成全部六阶段并发布ready，actual_llm_extraction、graph_ready和retrieval_ready均为true。公共来源、证据及端点检查通过；图记录从冻结文件构建并读回校验。主代理独立复跑过受影响的公共流水线、模型、图查询和界面检查。这些证据证明模块可协同运行，不能写成抽取准确率，也不能用某个开发问题的成功回答代替A/B总体结论。

P6已发布全部61个生产预测的逐项评审及40单元的正式抽取汇总[7]，评审覆盖为1.0，无漏评预测或未决参考。测试集30个完整单元得到TP25、FP19、FN1，Precision为25/44=0.5682，Recall为25/26=0.9615，F1为0.7143。开发集10单元为TP10、FP7、FN2，F1为0.6897。两组分开报告，不将调试数据与正式测试合并成总体成绩。

| 划分 | TP / FP / FN | Precision | Recall | F1 | 理由完整覆盖 |
|---|---|---|---|---|---|
| 开发10单元 | 10 / 7 / 2 | 0.5882 | 0.8333 | 0.6897 | 9 / 11 |
| 测试30单元 | 25 / 19 / 1 | 0.5682 | 0.9615 | 0.7143 | 13 / 15 |

测试集中有15个参考决定明确包含理由，13个成功抽中并完整保留理由，覆盖为0.8667。两项缺口分别为整条决定漏抽1和理由为空1；状态错误1与理由为空发生在同一项，不能相加成三个独立缺口。开发理由覆盖为9/11=0.8182，另两项为整条漏抽。结果表明，在本冻结银标下，系统召回较高而精度明显较低，仍有大量未匹配预测，不能只展示成功链或用高Recall掩盖这一问题。

独立模型银标本身并不完美。开发负例已保留一项已知银标遗漏，生产中有原文支持而银标缺失的预测仍按未匹配计算，没有在看过生产输出后回填参考。因此FP含义是相对冻结银标未匹配，不能全部解释为经人工确认的事实错误；这种限制与指标同时报告。12个源码快照的解析、顶层符号、模块说明及已发出Imports的引文和同SHA核验通过，但不构成未采依赖完整性或事件召回。

## 5.4 问答A/B与全池核验

24道题分别运行A、B两组，共形成48个答案，其中32个正常返回、15个为空结果、1个生产失败；24次匿名评审全部完成，覆盖48个答案中的全部claims和参考事实，公开汇总见[8]。20道测试题的结果如下表。A组事实覆盖30/50=0.600，B组为37/50=0.740；A组证据组召回35/55=0.636，B组38/55=0.691；A组无依据断言1/39=0.026，B组2/47=0.043。B组事实覆盖更高，但返回的claims更多、无依据断言率也更高，说明图扩展同时带来补充证据和额外噪声。

| 组别 | 事实覆盖 | 证据组召回 | 无依据断言率 | 中位延迟 |
|---|---|---|---|---|
| A：共同检索 | 30/50 = 0.600 | 35/55 = 0.636 | 1/39 = 0.026 | 2285 ms |
| B：A加图扩展 | 37/50 = 0.740 | 38/55 = 0.691 | 2/47 = 0.043 | 2688 ms |

15道具有配对事实覆盖的测试题中，B胜5题、A胜4题、6题持平；B减A的平均覆盖差为0.157。以固定种子20261030对题目做描述性配对bootstrap，95%区间为[-0.122, 0.457]，跨零且样本仅来自一个冻结项目，因此只能报告观察到的方向性差异，不能宣称显著收益或一般化因果效果。B组中位延迟比

A组高约403毫秒，也提示图扩展需要计算与上下文预算代价。

全池不足证据核验首轮92个位置中86个成功、6个因结构或引文校验失败。系统只对失败位置沿原分片和缓存做一次格式恢复重试，6个全部成功；旧失败记录与备份保留，最终92/92位置完成两遍核验。6道候选均出现非空证据，确认证据不足数为0，因此正确弃答率的分子为0、合格分母也为0，按约定记为N/A。该N/A的原因是核验完整但没有证据不足题，不是核验未完成；15个空结果和1个生产失败也不能自动记作正确弃答。若把检索未命中或服务失败算作弃答，会系统性高估系统能力。最终验收矩阵见[13]。

### 5.5 第二仓库迁移检查

pallets/itsdangerous使用同一python -m historykg.cli build <repo_url>入口和默认course_small_v1，没有手工选择讨论、SHA或文件，也没有修改源码、图关系或证据。最终作业形成347条来源、30个完整讨论单元、17个文件快照、82个实体、78条关系和180条证据；公共validate返回ok，graph_ready与retrieval_ready均为true。由于采集仍有10次HTTP 404、147个未补采显式引用、74个未采内部Import目标、60个发布可达性unknown和78个外部或未解析对象，作业整体状态保持partial。partial描述记录缺口，不否定已生成并校验的图和检索结果。公开验收见[11]。

真实依赖问题询问src/itsdangerous/timed.py导入或依赖哪些模块，返回50条路径、25条证据和5条claims，分别覆盖同包encoding、exc、serializer、signer以及标准库依赖。5条claim引用的evidence ID均可解析，所有引文均为冻结源码的逐字子串，来源SHA-256重新计算一致。另一条search查询返回empty，也作为查询状态保留。该答案只证明一只小型公开Python仓库可在不改代码的情况下完成有限迁移和可追溯依赖回答，不能扩展为全历史完整或任意体量仓库的通用保证。

Windows验证使用GitHub托管windows-2022环境安装锁定Python依赖，并启动原生PostgreSQL16.4及Neo4j5.26.0，重建合成fixture和公开Flask冻结包。公开平台验证摘要deliveries/P1/2026-10-30/platform_validation.json所对应run的150项JUnit测试无失败、无跳过，Flask冻结包首次加载与幂等重复加载均ready，数据集指纹保持 5cbe7b6f68a74d31ebf1fceeb7a00fd16d9b3737066b1ac7e9e51f90be955cfe，新增模型请求为0。macOS最新主线全量150项通过。该流程不配置模型密钥，不是Windows在线抽取或同学本机实测，缓存与重放均显式标记。

## 6 原型系统与使用展示

### 6.1 使用流程与证据展示

原型采用Streamlit单页面，按“提交仓库、观察构建、围绕已采历史提问”组织。安装者一次配置数据库、GitHub只读访问、DeepSeek密钥与共享预算后，使用者只需输入公开仓库链接。页面调用start_build、get_build和resume_build，显示后端真实阶段、完整单元、来源数和快照数。作业与dataset内部身份放入诊断区，避免让普通用户选择技术路径。

queued、running、blocked、failed和unsupported均不开放问答，只有ready或partial允许输入问题；partial持续展示缺口。页面重绘不重建任务，同一次响应保存在会话中，避免刷新重复调用模型。暂停或失败通过显式恢复入口接续检查点，不要求使用者重新选材料。界面不以“已抓到若干来源”代

替“可查询图已发布”。

答案按顺序呈现全部claims.text，每项链接到相应证据，包含原文、来源URL、作者时间、版本与位置。关系链来自公共查询结果，不由页面临时推断或美化；没有Decision时仍可呈现已有PR、提交及文件链。empty、unsupported和error分别解释资料不足、范围限制和调用故障。课堂备份模式读取带原运行时间的真实缓存，清楚标为重放并关闭在线输入，不能将重放计作在线时延。

### 6.2 真实案例与边界

真实页面已用同一Flask作业展示源码职责问题：在冻结的src/flask/testing.py中询问FlaskClient.session_transaction为何使用临时请求上下文及怎样处理会话与Cookie，系统返回6条claims，证据32至37逐条对应源码。每条claim可查看逐字引文、Unicode位置、来源编号、原始链接和数据版本；同一冻结重放包还保留一份empty响应，没有把资料不足改写为成功。界面与截图记录见[9]。

可用开发例是Flask PR6133：本地测试调整的明示理由是适应尚未发布的Werkzeug。修复后的抽取保留本地决定及理由，同时将Werkzeug新增client.query识别为外库候选，不挂到Flask主体；回答器输出带逐字引文的claims。该例属于已登记开发回归，说明具体问题怎样被发现和修正，不进入正式测试成绩，也不替代仅URL的产品验收。

页面可运行和单题可追溯只证明交互闭环，不能替代第5节的总体统计。截图、冻结响应和验证记录只对应同一作业与同一数据版本；换仓库后必须重新采集、抽取和建图，不能复用Flask的实体或答案。

### 6.3 期末展示材料

期末汇报统一采用demo/final/期末汇报_20261030最终版.pptx，共10页，覆盖研究问题、自动流程、Schema与证据契约、Developer/Function增量、真实数据范围、固定跨源链、原型问答、抽取与A/B结果、复现费用和六角色贡献。该目录另附逐页讲稿、演示步骤及10张精确重导入后的预览图。期中五页版本只作为历史阶段材料保留，不再代表期末状态；若PPTX原件尚未随当前文档提交入Git，最终打包前必须补齐并复核，不能只以预览图替代。材料说明见[14]。

## 7 复现、费用与局限

复现分三个层次。第一层使用已保存评分和统计代码重算数字，不再请求模型；第二层使用冻结来源、图记录和relore输入重建数据库与页面，验证哈希、幂等性及检索；第三层重新调用外部模型，要求使用者自己的账号、密钥和额度，并承认别名、服务版本及随机性可能导致输出不同。交付锁定依赖、固定上游、源码、公开冻结包、模型记录及实验归档，私有参考由P6在正式结束后按课程范围发布。

本次公开最小重建包保存原manifest和18份带哈希JSONL，以及无网络检索回放输入和明确标为事后补记的执行元数据。它不包含密钥、个人配置、完整clone或私有测试。未来源码变更与已有生产运行分别记录，不能用当前HEAD假装过去的执行版本。原manifest中历史个人capture路径仅作原运行出处记录，重建读取包内相对路径，无需原电脑目录。

费用由唯一SQLite账本以整数微元控制，请求前预留上界，失败和重试不消失。P4根据实际时段与缓存命中元数据对账，原保守记录保留历史语义；最终账本未重置，approved=20元、effective cap=19.84元，保守累计9.465795元，其中known usage 7.771385元、unknown upper 1.694410元，剩余10.374205元。全池重试和第二仓库运行分别新增0.502822元、0.589461元，合计1.092283元。P1的冻结重建和统计重算不产生新增模型请求，服务商账户余额也不替代内部账本审计。

方法存在若干实际局限。首先，有限近期采样无法恢复全生命周期，未采发布或文件不能凭空回答。其次，静态AST只提供局部依赖事实，动态导入与运行行为不在当前范围。再次，模型可能把观点误判为决定、遗漏理由或在引文真实时仍作出错误归属，格式和偏移校验不能证明语义正确。第四，独立模型参考与judge仍可能共享偏差，银标结果需要结合覆盖及分歧解释。第五，全池虽已完成92/92位置的两遍核验，但6道候选均未确认证据不足，正确弃答率因合格分母为0而N/A；该N/A不能解释为核验失败。第六，A/B实验仅覆盖一个冻结项目的20道测试题，配对区间跨零，不能据此宣称图谱普遍优于普通检索。第七，pallets/itsdangerous迁移作业因10次HTTP 404和147个未补采显式引用等缺口保持partial，单题通过不能外推为全历史完整或任意仓库通用。第八，Neo4j在最终审计时可连接记录已保存，但实时bolt/HTTP服务未保持在线，最终打包前仍需复验服务可用性。图谱将这些信息显式组织，但不会自动消除错误。

## 8 结论与后续工作

项目已将公开仓库URL、完整讨论采集、有限代码事实、真实模型抽取、显式图和同源检索接入一个可恢复流程。统一证据契约使讨论、API、git与源码能够使用同一套原文位置复算，关系语义则限制了从文本声明到历史事实的无依据升级。真实Flask生产作业证明这条有限流程可以执行并发布，冻结包支持无新增模型请求的重建。

正式抽取测试显示银标F1为0.7143、理由覆盖为13/15，同时精度0.5682暴露出预测与参考的明显分歧。下游20道测试题中，图扩展组事实覆盖由0.600升至0.740，但配对差0.157的95%描述性区间跨零，且B组无依据断言率和延迟更高，因此结论是“观察到方向性收益，但证据不足以宣称显著或普遍有效”。全池92/92位置完成两遍核验，6道候选均确认证据充分，正确弃答率因无合格题而N/A；pallets/itsdangerous以partial状态完成受限迁移，依赖答案的50条路径、25条证据和5条claims均可追溯。后续工作应优先处理真实采集缺口、Windows实机与PowerPoint检查、实时服务复验和人工核验，而不是根据分数修改冻结来源或删除难例。期末材料包含PDF、10页期末PPT、代码数据及复现材料；真实成员姓名、学号、互评与课堂表达由成员本人完成。

## 9 人员与工作安排及组内互评

以下只列可由仓库、冻结数据、运行记录或交接核对的角色贡献。P4前期独立调研、总体方案、架构迭代、规划协作框架、期初原型与试跑保留原贡献归属，不因后续模块接收而转记给集成者。姓名、学号和互评不根据Git提交作者、聊天昵称或文件名推断。

| 角色 | 主要职责 | 可核验贡献 | 证据 |
| --- | --- | --- | --- |
| P1 数据与集成 | 公共数据契约、URL发现、唯一作业编排、冻结、总集成与报告统稿 | 实现来源与证据契约、稳定身份、可恢复流水线；完成Flask URL作业369来源、40完整讨论和24快照；组织150项跨平台测试并统稿候选报告 | historykg/pipeline.py；deliveries/P1/2026-10-30/handoff.md；platform_validation.json |
| P2 图谱与查询 | 图模式导入、Neo4j、同源检索隔离与公共查询 | 发布133实体、183关系、333证据；实现数据集过滤、查询服务、A/B共同检索与图扩展接口 | historykg/graph/store.py；historykg/query/；deliveries/P2/2026-10-30/handoff.md |
| P3 代码与演化 | 提交、发布、文件和静态代码事实 | 自动定位24个文件乘SHA快照；只读增量生成18 Developer、384 Function、20 Authored、4 Merged、384 Defines及508条证据；核对PR #6096到函数定义的固定链 | historykg/code/；deliveries/P3/2026-10-30/developer_function_validation.json；deliveries/P3/2026-10-30/developer_function_handoff.md |
| P4 开源移植与模型抽取 | relore移植、采集接口、模型通道、Decision抽取与统一回答 | 固定relore 0.3.19源码并保留许可证；完成40个生产抽取run和42次尝试；实现共享账本、理由抽取、回答器及费用对账 | vendor/relore/UPSTREAM.json；historykg/llm/；historykg/extract/；deliveries/P4/2026-10-30/formal_validation.json |
| P5 原型与汇报 | 页面、状态呈现、证据交互与展示材料 | 完成Streamlit构建与问答界面、冻结响应重放、21项界面回归、真实页面截图及10页期末汇报材料 | app/；demo/replay/flask-public-20261030.json；demo/final/期末汇报_20261030最终版.pptx |
| P6 参考与实验 | 独立参考、主题隔离、全池核验、A/B统计与图表 | 完成40线程参考、24题参考、48个答案和24次匿名评审；完成92/92全池两遍核验、第二仓库验收和最终预算审计 | historykg/evaluation/；evaluation/results/formal_summary.json；evaluation/results/second_repo_acceptance.json |

工作安排按“开发数据修复、冻结测试评价、候选统稿、成员核对与现场展示”组织。P1负责集成和材料一致性，P2/P3/P4/P5/P6分别对图查询、代码事实、模型链路、页面展示和独立实验负责；跨模块缺陷由所属角色修复，P1只做接口协调和集成验收。计划节点为11月11日期中、12月20日内部完整候选，期末实际提交日期以教师通知为准。

## 9.1 成员信息与贡献确认表

下表必须由六位成员本人核对和填写；空白项不表示AI已确认，也不得用Git作者名代替真实姓名。

| 角色 | 真实姓名 | 学号 | 本人核对职责与贡献 | 本人补充说明 | 签名与日期 |
|---|---|---|---|---|---|
| P1 | 待本人填写 | 待本人填写 | 待本人核对表1对应行 | 待本人填写 | 待本人填写 |
| P2 | 待本人填写 | 待本人填写 | 待本人核对表1对应行 | 待本人填写 | 待本人填写 |
| P3 | 待本人填写 | 待本人填写 | 待本人核对表1对应行 | 待本人填写 | 待本人填写 |
| P4 | 待本人填写 | 待本人填写 | 待本人核对表1对应行 | 待本人填写 | 待本人填写 |
| P5 | 待本人填写 | 待本人填写 | 待本人核对表1对应行 | 待本人填写 | 待本人填写 |
| P6 | 待本人填写 | 待本人填写 | 待本人核对表1对应行 | 待本人填写 | 待本人填写 |

### 9.2 组内互评汇总表

每格由评价人本人按1至5分填写，并在表后附至少一条可核对事实和一条改进建议；对角线不评价本人。本表只作报告汇总，不能代替课程平台要求的原始互评表，也不得由AI生成、补分或代签。

| 评价人 \ 被评价人 | P1 | P2 | P3 | P4 | P5 | P6 |
|---|---|---|---|---|---|---|
| P1 | 不评价本人 | 待本人填写 | 待本人填写 | 待本人填写 | 待本人填写 | 待本人填写 |
| P2 | 待本人填写 | 不评价本人 | 待本人填写 | 待本人填写 | 待本人填写 | 待本人填写 |
| P3 | 待本人填写 | 待本人填写 | 不评价本人 | 待本人填写 | 待本人填写 | 待本人填写 |
| P4 | 待本人填写 | 待本人填写 | 待本人填写 | 不评价本人 | 待本人填写 | 待本人填写 |
| P5 | 待本人填写 | 待本人填写 | 待本人填写 | 待本人填写 | 不评价本人 | 待本人填写 |
| P6 | 待本人填写 | 待本人填写 | 待本人填写 | 待本人填写 | 待本人填写 | 不评价本人 |

成员完成核对后，应将上述成员信息表、互评表和事实说明一并提交；在此之前，本报告只能作为期末候选，不能把空白互评视为零分、默认通过或已完成。

## 参考文献

[1] Hugging Face. relore: Search the decisions behind the code. https://github.com/huggingface/relore . 本项目固定源码提交06a1c99c4653e9db899a18e96d8ff0ee6b419815，版本0.3.19，访问日期2026-10-30。

[2] GitHub. Issue event types: closed. https://docs.github.com/en/rest/using-the-rest-api/issue-event-types#closed . 访问日期2026-10-30。

[3] Neo4j. Cypher Manual: Create constraints. https://neo4j.com/docs/cypher-manual/current/schema/constraints/create-constraints/ . 本项目运行版本5.26.0，访问日期2026-10-30。

[4] DeepSeek. Chat Completions API. https://api-docs.deepseek.com/zh-cn/api/create-chat-completion/ . 访问日期2026-10-30。

[5] Pallets. Flask source repository. https://github.com/pallets/flask . 具体来源、URL、作者、采集时间及哈希以冻结数据包为准。

[6] 课程项目说明：课程选题-1.pdf与课程选题_更新.pdf，选题3及报告要求，课程下发资料。

[7] 本项目P6. 正式抽取公共汇总evaluation/results/extraction_summary.json，feat/p6提交0b02114，2026-10-30。统计范围为独立模型银标，非人工金标。

[8] 本项目P6. 正式实验公共汇总evaluation/results/formal_summary.json，2026-10-30。包含抽取、A/B、全池核验与费用快照；统计范围为模型银标，非人工金标。

[9] 本项目P5. 原型系统与展示章节、正式结果验证及冻结响应 replay，2026-10-30。界面证据对应Flask作业b61942bf06b742e48860d064dffe6df2与dataset:810db3718867788c5acb0fa437cdbf62bc0f99cd8e7435e9261471225f5cd00c。

[10] Pallets. itsdangerous source repository. https://github.com/pallets/itsdangerous . 第二仓库冻结源码快照为672971d66a2ef9f85151e53283113f33d642dabd，访问日期2026-10-30。

[11] 本项目P6. 第二仓库验收evaluation/results/second_repo_acceptance.json，2026-10-30。包含347来源、30完整讨论、17文件快照、82实体、78关系、180证据及50路径依赖回答。

[12] 本项目P3. Developer与Function增量验证deliveries/P3/2026-10-30/developer_function_validation.json，2026-10-30。包含18 Developer、384 Function、20 Authored、4 Merged、384 Defines与508条证据。

[13] 本项目P6. 最终验收矩阵evaluation/results/final_acceptance.json，2026-10-30。记录92/92全池核验、零证据不足分母、预算与第二仓库验收状态。

[14] 本项目P5. 期末汇报材料说明与10页最终PPT demo/final/期末汇报_20261030最终版.pptx，2026-10-30。P1不改写P5演示文件。